

LEHRSTUHL FÜR RECHNERARCHITEKTUR UND PARALLELE SYSTEME
Praktikum Rechnerarchitektur

Parallele Berechnung der Mandelbrotmenge
Wintersemester 2018/19

Maximilian Frühauf

Tobias Klausen

Florian Lercher

Niels Mündler

Inhaltsverzeichnis

| | |
|--|----------|
| 1 Einleitung | 3 |
| 1.1 Didaktische Ziele | 3 |
| 1.2 Verwendung der Mandelbrotmenge | 3 |
| 1.3 Darstellung der Mandelbrotmenge | 4 |
| 1.4 MPI | 5 |
| 1.5 Qualitätsanforderungen | 5 |
| 1.6 Einschränkungen | 5 |
| 2 Problemstellung und Motivation | 6 |
| 3 Dokumentation der Implementierung | 7 |
| 3.1 Übersicht | 7 |
| 3.2 Installation der Anwendung | 7 |
| 3.2.1 Lokales Backend | 8 |
| 3.2.2 Backend auf HimMUC Cluster | 8 |
| 3.2.3 Installation des Frontends | 12 |
| 3.3 Erläuterung des Backends | 12 |
| 3.4 Implementierung der Mandelbrotberechnung | 12 |
| 3.4.1 Inkludierte Header und CMake Anweisungen | 13 |
| 3.4.2 Mainfunktion und Initialisierung | 14 |
| 3.5 Host Funktionalitäten | 14 |
| 3.5.1 WebSocketverbindung | 14 |
| 3.6 Lastbalancierung | 18 |
| 3.6.1 Naive Strategie | 21 |
| 3.6.2 Strategie mit Vorhersage | 22 |
| 3.6.3 Erweiterung | 24 |
| 3.7 Kommunikation der Prozesse per MPI | 26 |
| 3.7.1 Genereller Aufbau der MPI-Kommunikation | 28 |
| 3.7.2 Übertragung neuer Rechenaufträge vom Host an die Worker | 31 |
| 3.7.3 Übertragung der berechneten Daten von den Workern zum Host | 34 |
| 3.8 Berechnung der Mandelbrotmenge | 36 |
| 3.8.1 Berechnung ohne SIMD | 37 |
| 3.8.2 Berechnung mithilfe von SIMD | 38 |
| 3.9 Erläuterung des Frontends | 38 |
| 3.9.1 Kommunikation mit dem Backend | 41 |

| | | |
|----------|---|-----------|
| 3.9.2 | Darstellung der Regionsdaten | 42 |
| 3.9.3 | Visualisierung der Programmstruktur | 45 |
| 3.9.4 | Visualisierung der Rechenzeiten | 46 |
| 3.9.5 | MISC | 46 |
| 4 | Ergebnisse / Evaluation | 47 |
| 5 | Zusammenfassung | 48 |

1 Einleitung

Die Leistung und Geschwindigkeit des individuellen Rechenkerns stagniert seit einigen Jahren. Moderne Computer erlangen einen Großteil ihrer erhöhten Rechenleistung seit einiger Zeit nur noch durch Parallelisierung. Diese sollte jedoch geschickt gestaltet werden, um unerwünschte Seiteneffekte wie Leerlauf zu vermeiden.

1.1 Didaktische Ziele

Das zugrundeliegende Problem ist, dass bei der Lastaufteilung einer unabhängigen Menge von Berechnungen in einem Cluster eine fixe Zuordnung von zu berechnenden Bereichen auf Rechenkerne erzeugt wird. Dauert die Bearbeitung eines Bereiches jedoch deutlich kürzer als diejenige anderer Abschnitte, so verbringt der reservierte Rechenkern die Zeit bis zum Abschluss der anderen Berechnungen ohne Arbeit und verbraucht Strom und Platz im Idle-Mode. Da die Kerne eines Clusters jedoch darauf ausgelegt sind, ständig zu arbeiten, sollte dieser Zustand vermieden werden, um Zeit, Kosten und Energie zu sparen.

Dies kann erreicht werden, indem die Einteilung der Rechenbereiche die vorraussichtliche Rechendauer berücksichtigt. Dazu werden rechenintensive Bereiche verkleinert und umgekehrt Bereiche mit geringerer Rechenlast vergrößert. Ziel sollte sein, dass alle Knoten für die Bearbeitung in etwa gleich lang brauchen, sodass die gegenseitige Wartezeit minimiert wird.

Dieses Projekt soll intuitiv vermitteln, dass bei der Aufteilung unabhängiger Berechnungen auf ein Cluster eine Abschätzung der benötigten Rechenlast die Gesamtrechendauer deutlich verringern kann. Außerdem soll ersichtlich sein, wie die verwendete Aufteilung bestimmt wird.

1.2 Verwendung der Mandelbrotmenge

Die Mandelbrotmenge ist eine Teilmenge der komplexen Zahlen. Um sie zu berechnen wendet man folgende Formel wiederholt auf jede komplexe Zahl c an:

$$z_{n+1} = z_n^2 + c, \quad z_0 = 0 \tag{1}$$

In der Mandelbrotmenge befinden sich alle c , für die der Betrag von z_n für beliebig große n endlich bleibt. Wenn der Betrag von z nach einer Iteration größer als 2 ist, so strebt z gegen unendlich, das zugehörige c liegt also nicht in der Menge. Sobald $|z_n| > 2$ kann die Berechnung daher abgebrochen werden.

Um nun für eine beliebige Zahl zu bestimmen, ob diese in der Mandelbrotmenge liegt, müssen theoretisch unendlich viele Rechenschritte durchgeführt werden. Zur computergestützten Bestimmung werden die Rechenschritte nach einer bestimmten Iteration abgebrochen die Zahl als in der Menge liegend betrachtet.

Es handelt sich also um eine Berechnung, die sehr zeitaufwändig ist, wobei die benötigte Zeit durch Erhöhen der Iterationszahl beliebig erhöht werden kann. Zusätzlich ist die Berechnung für jede einzelne komplexe Zahl unabhängig von jeder anderen Zahl.



Abbildung 1: Die Mandelbrotmenge, visualisiert in einem Ausschnitt des komplexen Zahlenraumes.

Diese Eigenschaften ermöglichen es, zweierlei Dinge zu kontrollieren:

- Die Dauer der Berechnung
- Die Aufteilung der Berechnung auf unterschiedliche Rechenkerne

Somit kann gesichert werden, dass eine wahrnehmbare Zeit (100-200 ms) zur Berechnung benötigt wird. Zudem kann die Unterteilung des zu berechnenden Raumes frei gewählt werden, sodass für verschiedenste Aufteilungen die Gesamtrechenzeit visualisiert werden kann.

1.3 Darstellung der Mandelbrotmenge

Komplexe Zahlen lassen sich auch grafisch darstellen, indem man sie in ein Koordinatensystem einträgt. Dabei entspricht die x-Koordinate dem Realteil und die y-Koordinate dem Imaginärteil der Zahl. Für das Projekt wird ein Ausschnitt des Bildschirmes als zweidimensionale Darstellung des komplexen Raumes betrachtet und für jeden darin liegenden Punkt die Zugehörigkeit zur Mandelbrotmenge bestimmt. Dabei wird der Raum jedoch diskretisiert, indem jedem Pixel des Bildschirmes die komplexen Koordinaten c der linken oberen Ecke zugeordnet werden.

Die grafische Darstellung der Mandelbrotmenge wird durch Einfärbung des zu c gehörigen Pixels erhalten. Die Zahl der benötigten Iterationen bis zum Abbruch der Berechnung bestimmt dabei die Farbe, sodass alle Pixel innerhalb der Menge und alle Pixel außerhalb jeweils gleichfarbig sind.

Das entstehende Fraktal ist aufgrund seiner Form auch als "Apfelmännchen" bekannt (siehe Abbildung 1). Die Menge ist zusammenhängend, jedoch bilden sich an ihren Rändern viele kleine und sehr komplexe Formen, die visuell ansprechend sind. Es eignet sich daher gut, um optisch Interesse am Projekt zu wecken.

1.4 MPI

Das Message Passing Interface¹ ist eine weit verbreitete Spezifikation, für die Kommunikation zwischen unabhängigen Rechenkernen. Dadurch existieren viele gut funktionierende Umsetzungen in einer Vielzahl von Programmiersprachen. Für dieses Projekt wichtig ist, dass es echte Parallelisierung mit geringem Overhead ermöglicht. So können die einzelnen Berechnungen auf jeweils eigenen unabhängigen Rechenkernen laufen und die Art der Aufteilung erhält größtmögliche Bedeutung. Die Gestaltung von MPI erlaubt dabei beliebige Zuordnungen, von Kernen auf einem Prozessor bis hin zu unabhängigen Clusterknoten, die lediglich eine SSH-Verbindung besitzen.

1.5 Qualitätsanforderungen

Die Benutzeroberfläche soll so leicht und intuitiv wie möglich zu bedienen sein. Hierbei soll zudem darauf geachtet werden, dass alle Funktionen nur mit einer minimalen Anzahl an Mausklicks auszuführen sind und die Oberfläche nicht überladen wird.

Zudem soll das System robust gestaltet werden. Dies wird durch die Verwendung von Buttons, Listen, Drop-Down Menüs und Slider gewährleistet, die die Möglichkeit der Eingabe von ungültigen Werten verhindern.

Es sind keine Sicherheitsfeatures (Benutzerauthentisierung, Verschlüsselung) geplant, da keine sensiblen Daten verarbeitet werden und die Anwendung nicht uneingeschränkt über das Internet zugänglich ist.

1.6 Einschränkungen

Die Benutzeroberfläche soll in einem Webbrower lauffähig sein, sodass sie auf beliebigen Endgeräten zugänglich gemacht werden kann. Um die erwartete Performanzsteigerung an einem echten Beispiel zu demonstrieren, soll die Berechnung der Mandelbrotmenge parallel auf mehreren Raspberry Pi's² oder ähnlichen unabhängigen Kleincomputern oder Rechenkernen zum Einsatz kommen soll.

¹<https://www.mpi-forum.org/>

²Für ein Beispiel, siehe <https://www.raspberrypi.org/products/raspberry-pi-3-model-b/>

2 Problemstellung und Motivation

- Fachliche Spezifikation in Anhang
- NFRs in Einleitung schreiben

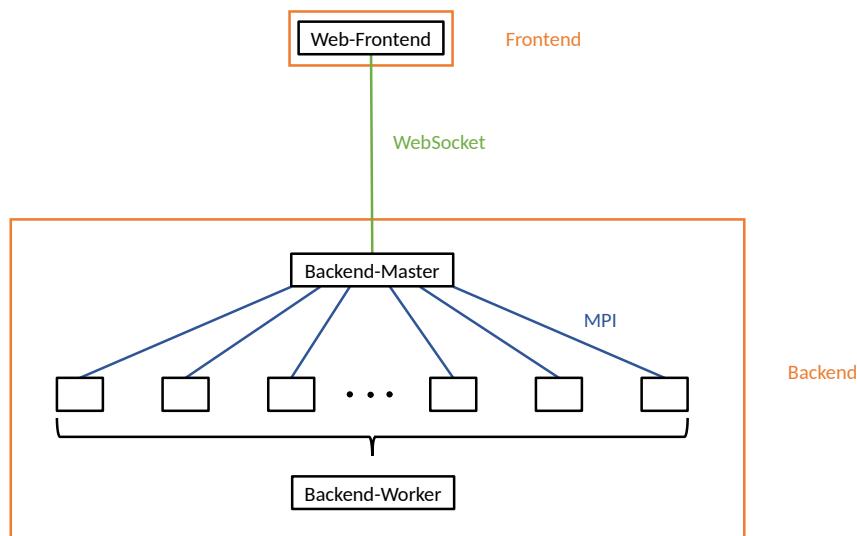


Abbildung 2: Architekturübersicht

3 Dokumentation der Implementierung

3.1 Übersicht

Das Problem fordert eine Unterteilung in drei wesentliche Bausteine, wie sie in Abbildung 2 zu sehen sind. Eine Benutzeroberfläche in einem Web Browser des Benutzers ("Frontend"), welches die Benutzerinteraktionen entgegennimmt und mit dem Backend kommuniziert. Ein Backend-Host übernimmt dazu die Kommunikationsfunktion, verwaltet die eingehenden Rechenaufträge und verteilt sie an die Backend-Worker. Das Ergebnis dieser Berechnung sendet der Host dann an das Frontend zurück. Die Backend-Worker nehmen die zugewiesenen Rechenaufträge entgegen und führen die eigentlichen Berechnungen verteilt aus.

3.2 Installation der Anwendung

Um das System zu installieren, muss das Repository mit git³ lokal geklont werden. Dabei werden die Quelldateien für das Front- sowie Backend heruntergeladen.

```
1 git clone https://gitlab.lrz.de/lrr-tum/students/eragp-mandelbrot.git
```

Quelltext 1: Klonen des Repositorys

³<https://git-scm.com/>

3.2.1 Lokales Backend

Eine lokale Installation des Backends zu Entwicklungszwecken ist durch einen Docker⁴ Container möglich. Dieser bietet eine ähnliche Umgebung zu der des Clusters und ermöglicht schnellere Feedbackzyklen.

```

1 # Systemabhängige Installation der Docker Anwendung
2 $ sudo apt install docker
3 cd backend/ && ./run_docker.sh
4 Starting the Build Process
5 ...
6 Host: Core 37 ready!
7 # ^C beendet das Backend und verbindet sich mit der shell des Containers
8 ^C[mpiexec@9cc2d5ac2cd1] Sending Ctrl-C to processes as requested
9 [mpiexec@9cc2d5ac2cd1] Press Ctrl-C again to force abort
10 # exit schliesst die shell des Containers
11 root@9cc2d5ac2cd1:~/eragp-mandelbrot/backend# exit

```

Quelltext 2: Starten der Entwicklungsumgebung des Backends

Das `run_docker.sh` Skript lädt das benötigte Basis Image, welches alle benötigten Bibliotheken bereits enthält, herunter und erstellt basierend darauf den Entwicklungskontainer. In diesen werden dann die aktuellen Quelldateien hinein kopiert und kompiliert, wonach das Backend mit Adresse `ws://localhost:9002` gestartet wird.

3.2.2 Backend auf HimMUC Cluster

[Der] HimMUC ist ein flexibler Cluster von ARM-Geräten, bestehend aus 40 Raspberry Pi 3 sowie 40 ODroid C2 Single-Board-Computers (SBC).⁵

Schnellstart Um das Programm auf dem HimMUC Cluster zu starten, wurde ein Python Skript erstellt, das alle notwendigen Schritte übernimmt. Es führt die Befehle aus Abschnitt 3.2.2 aus, es kann daher bei Problemen zur Fehlerbehebung herangezogen werden.

Stellen sie zunächst sicher, dass sie ein Konto mit Zugangsberechtigungen auf dem HimMUC Cluster besitzen. Um den eigenen Quellcode auf dem Cluster zu kompilieren muss für die korrekte Funktionsweise des Skriptes zudem ihr SSH-Key auf dem Cluster abgelegt sein⁶.

Außerdem sollten folgende Programme lokal installiert sein:

- rsync
- ssh
- python3 (3.5 oder neuer)

⁴<https://www.docker.com/>

⁵<http://www.caps.in.tum.de/himmuc/>

⁶siehe `ssh-copy-id`

Starten sie anschließend aus dem Ordner `backend/` den Befehl aus Quelltext 3

```
1 python3 himmuc/start_himmuc.py <Rechnerkennung> <Anzahl Prozesse> <Anzahl Rechenknoten>
```

Quelltext 3: Start der Entwicklungsumgebung auf dem HimMUC

Das Ergebnis wird ähnlich zu Quelltext 4 aussehen. Details zu weiteren Optionen des Skripts sind via `--help` verfügbar.

Detaillierter Start Um Mandelbrot manuell auf dem Host-System zu installieren, müssen zunächst die notwendigen Bibliotheken installiert werden. Eine Anleitung dazu findet sich in Abschnitt 3.2.2. Dies muss nur einmal ausgeführt werden, anschließend können die Programme wie in Abschnitt 3.2.2 beschrieben kompiliert werden. Ist dies nicht gewünscht oder erledigt muss das Backend lediglich noch wie in Abschnitt 3.2.2 beschrieben gestartet werden.

Lokale Installation der Bibliotheken Da hierbei davon ausgegangen wird, dass keine root-Rechte auf dem Server existieren, werden die Bibliotheken hier lokal in `~/eragp-mandelbrot` installiert. Achten Sie darauf, dass sie Schreibrechte auf dem Ordner haben und falls sie einen anderen Ordner verwenden wollen, ersetzen sie jedes Vorkommen des Pfades durch ihren Pfad (insbesondere in der Datei `CMakeLists.txt`). Die MPI-Bibliothek ist auf dem HimMUC Cluster bereits vorinstalliert und muss daher nicht mehr aufgesetzt werden.

Die 'Header-only' Libraries `websocketpp` und `rapidjson` müssen lediglich an einen fixen Ort kopiert werden. Dies erledigen die Befehle aus Quelltext 6.

Aus der Bibliothek `boost` muss die Teilbibliothek `boost_system` lokal kompiliert werden. Dazu werden die Befehle aus Quelltext 7 ausgeführt, um die Version 1.67.0 herunterzuladen, zu entpacken und lokal zu installieren. Beachten Sie, dass das kompilieren auch wie in Abschnitt 3.2.2 beschrieben von einem der Boards ausgeführt werden muss.

Kompilieren des Backends Stellen Sie zunächst sicher, dass auf dem Cluster die Quelldateien des Backendes (im Ordner `backend/`) liegen (zum Beispiel über `rsync` oder indem sie das Repository dort auch klonen). Zum Kompilieren des Backends sollte sich auf einen Raspberry Pi oder ODroid per ssh eingeloggt werden⁷

Auf dem Board, aus dem Ordner des Backendquellcodes müssen Sie zum kompilieren des Backendes die Befehle aus Quelltext 8 ausführen.

Ausführen des Backends Um das Backend auf dem HimMUC Cluster laufen zu lassen, muss sich zunächst darauf per ssh eingeloggt werden. Damit für das Frontend kein Unterschied dazwischen besteht, ob das Backend im Dockercontainer, oder auf

⁷Es existiert ein Entwicklerzugang zu einem geteilten Raspberry Pi über die Adresse `sshgate-geasp.in.tum.de`. Dieser wird auch vom Python Skript genutzt

```

1 $ eragp-mandelbrot/backend$ python3 himmuc/start_himmuc.py muendlar 10 9
2 Uploading backend... sending incremental file list
3 backend/himmuc/start_backend.py
4     3,897 100%    3.05MB/s   0:00:00 (xfr#1, to-chk=35/62)
5 done
6 Start mandelbrot with 1 host and 9 workers on 9 nodes... started
7     mandelbrot
8 Search host node... srun: error: Could not find executable worker
9 odr00 found
10 Establish port 9002 forwarding to host node odr00:9002 ... established
11 System running. WebSocket connection to backend is now available at
12     ws://himmuc.caps.in.tum.de:9002
13 Press enter (in doubt, twice) to stop Warning: Permanently added the
14     ED25519 host key for IP address '10.42.0.54' to the list of known
15     hosts.
16 # Enter
17
18 Stopping port forwarding... stopped (-9)
19 Stopping mandelbrot host and workers... stopped (-9)

```

Quelltext 4: Beispielausgabe bei Start der Entwicklungsumgebung auf dem HimMUC

```
1 mkdir ~/.eragp-mandelbrot
```

Quelltext 5: Erstellen des Installationsordners

```

1 mkdir "~/eragp-mandelbrot/install"
2 cd "~/eragp-mandelbrot/install"
3 # Installation von websocketpp
4 git clone --branch 0.7.0 https://github.com/zaphoyd/websocketpp.git
5 # Installation von rapidjson
6 git clone https://github.com/Tencent/rapidjson/

```

Quelltext 6: Lokale Installation der Bibliotheken websocketpp und rapidjson.

einem externen Server ausgeführt wird, ist bei der ssh-Verbindung der Port 9002 des himmuc.caps.in.tum.de-Servers an den lokalen Port 9002 gebunden. So ist das Backend stets unter localhost:9002 verfügbar. Der zugehörige Befehl zum Login lautet demnach:

```
1 ssh <rechnerkennung>@himmuc.caps.in.tum.de -L localhost:9002:localhost
:9002
```

Anschließend muss aus dem Ordner, in dem die ausführbaren Dateien liegen, für gewöhnlich also der ~/eragp-mandelbrot/build/ Ordner, folgender Befehl ausgeführt werden:

```

1 # Erstellen der notwendigen Ordnerstrukturen
2 mkdir "~/.eragg-mandelbrot/install"
3 mkdir "~/.eragg-mandelbrot/local"
4 # Einrichten des Internetproxys
5 export http_proxy=proxy.in.tum.de:8080
6 export https_proxy=proxy.in.tum.de:8080
7 # Herunterladen und kompilieren der Boost-Bibliothek
8 cd "~/.eragg-mandelbrot/install"
9 wget "https://dl.bintray.com/boostorg/release/1.67.0/source/boost_1_67_0.tar.bz2"
10 tar --bzip2 -xf boost_1_67_0.tar.bz2
11 cd boost_1_67_0
12 ./bootstrap.sh --prefix="$HOME/.eragg-mandelbrot/local/" --with-libraries=system
13 ./b2 install

```

Quelltext 7: Lokale Installation der Bibliothek boost.

```

1 # Erstellen und betreten eines build Ordners
2 mkdir build
3 cd build
4 # Aktivieren der MPI Bibliothek
5 module load mpi
6 # Kompilieren
7 cmake ..
8 make

```

Quelltext 8: Kompilieren des Backends

```

1 srun -p <odr|rpi> -n <number of workers+1> -N <number of nodes/raspis> -l
   --multi-prog <path to eragg-mandelbrot/backend>/himmuc/run.conf &
2 ssh -L 0.0.0.0:9002:localhost:9002 -fN -M -S .tunnel.ssh <odr|rpi><host
   number>

```

Dabei bestimmt **-n** die Anzahl der laufenden Prozesse (Also Hostprozess und Workerprozesse) und **-N** die Anzahl zu verwendender Rechenknoten. Damit anschließend noch alle Anfragen an den WebSocketserver auf dem Hostknoten weitergeleitet werden, muss noch der Port 9002 des `himmuc.in.caps.tum.de`-Servers an den Port 9002 des Rechenknotens gebunden werden, auf dem der Hostprozess läuft. Der korrekte Knoten ist dabei der Ausgabe des `srun`-Befehles zu entnehmen. Eine beispielhafte Ausgabe ist in Quelltext 9 zu sehen.

Stoppen des Backends Um das Backend wieder zu stoppen, müssen der `ssh`-Tunnel zur Verbindung der Ports und der `srun`-Prozess gestoppt werden. Letzterer lässt sich nach dem dämonisieren im vorigen Aufruf nur über die Prozess-ID finden. Diese zeigt das Tool `ps` an.

```

1 ssh -S .tunnel.ssh -O exit rpi<host number>
2 # To stop the node allocation

```

```

1 muendl@vmschulz8:~/eragt-mandelbrot/backend/build$ srun -N4 -n5 -l --
  multi-prog ./himmuc/run.conf
2 srun: error: Could not find executable worker
3 4: Worker: 4 of 5 on node rpi06
4 2: Worker: 2 of 5 on node rpi04
5 3: Worker: 3 of 5 on node rpi05
6 0: Host: 0 of 5 on node rpi03
7 0: Host init 5
8 1: Worker: 1 of 5 on node rpi03
9 0: Core 1 ready!
10 1: Worker 1 is ready to receive Data.
11 2: Worker 2 is ready to receive Data.
12 0: Listening for connections on to websocket server on 9002
13 0: Core 2 ready!
14 3: Worker 3 is ready to receive Data.
15 0: Core 3 ready!
16 4: Worker 4 is ready to receive Data.
17 0: Core 4 ready!
18 muendl@vmschulz8:~/eragt-mandelbrot/backend/build$ ssh ssh -L
  0.0.0.0:9002:localhost:9002 -fN -M -S .tunnel.ssh rpi03

```

Quelltext 9: Beispielhafter Start des Backends. Hierbei ist der Knoten des Hostprozesses rpi03.

```

3 ps -eo comm,pid | grep srun
4 kill <srun pid>

```

3.2.3 Installation des Frontends

Das Frontend ist in TypeScript⁸ (erweiterung von JavaScript⁹) geschrieben und kann somit auf einem beliebigen Endgerät mit einem modernen Webbrowser ausgeführt werden. Um eine Version lokal zu starten, muss die Paketverwaltung npm¹⁰ installiert werden. Diese verwaltet alle für das Frontend benötigten Bibliotheken und installiert diese lokal.

Das Kommando `npm start` startet dabei einen lokalen WebServer, welcher eine kompilierte Version des Frontends unter der Adresse `http://localhost:3000` anbietet. Danach wird der Standardwebbrowser des Systems verwendet, um diese URL zu öffnen.

3.3 Erläuterung des Backends

3.4 Implementierung der Mandelbrotberechnung

Zur hardwarenahe Berechnung der Mandelbrotmenge wird ein sogenanntes Backend gestartet. Das in C++ programmierte Teilprojekt nimmt Rechenaufträge von einem Nutzer durch ein Frontend entgegen (auch ein solches wird bereitgestellt), zerlegt sie

⁸<https://www.typescriptlang.org/>

⁹<https://en.wikipedia.org/wiki/JavaScript>

¹⁰<https://www.npmjs.com/>

```

1 # Systemabhängige Installation der npm Paketverwaltung
2 sudo apt install npm
3 # Installiert benötigte Bibliotheken und startet WebServer
4 cd frontend/ && npm install ; npm start
5 ...
6 Version: webpack 4.25.1
7 Time: 7230ms
8 Built at: 12/28/2018 10:48:32 PM
9          Asset      Size  Chunks             Chunk Names
10        index.html  1.65 KiB          [emitted]
11 mandelbrot.js   11.7 MiB    main  [emitted]  main
12       style.css   519 KiB    main  [emitted]  main
13 Entrypoint main = style.css mandelbrot.js
14 ...

```

Quelltext 10: Starten des Frontends mit beispielhafter Ausgabe

und verteilt sie per MPI auf dedizierte Rechenknoten. Dazu besteht das Backend aus zwei ausführbaren Dateien, host und worker.

3.4.1 Inkludierte Header und CMake Anweisungen

Die zusammenstellung der ausführbaren Dateien wird in CMake definiert. Dabei unterscheiden sich diese lediglich in den eingebundenen Quelldateien: In die Datei host werden host.main.cpp und actors/Host.cpp eingebunden, während in worker worker.main.cpp und actors/Worker.cpp eingebunden werden.

Diese und alle weiteren Build-Vorgaben werden in der Datei CMakeLists.txt für cmake¹¹ in der hier beschriebenen Reihenfolge spezifiziert. Es sollte hierbei eine CMake-Version über 3.7.0 gewählt werden und die C++11 Standards¹² werden vorrausgesetzt. Zudem werden für das Projekt "Mandelbrot" werden alle Dateien im Order include eingebunden. In diesem Ordner liegen die Header-Dateien für alle projektinternen C++-Quelldateien. Anschließend werden alle C++-Quelldateien (Endung ".cpp") aus dem Ordner src in einer Liste gesammelt, mit Ausnahme jedoch der oben genannten, exklusiven Quelldateien. Die erzeugte Liste und die jeweils exklusiven Dateien werden dann den ausführbaren Dateien host und worker zugeordnet.

Um die verwendeten Bibliotheken verfügbar zu machen werden anschließend die Header der installierten MPI-Bibliothek sowie die Header der Bibliotheken rapidjson¹³, websocketpp¹⁴ und boost¹⁵. Diese werden respektive verwendet um JSON zu parsen und enkodieren, WebSocket-Verbindungen aufzubauen und darüber zu kommunizieren sowie um diese Bibliothek zu unterstützen. Da für die boost Bibliothek dabei Header nicht

¹¹Ein Programm, welches die Erstellung von Makefiles vereinfacht in dem es sie automatisch an die Umgebung des Build-Systems anpasst. <https://cmake.org/>

¹²<https://isocpp.org/wiki/faq/cpp11>

¹³<http://rapidjson.org>

¹⁴<https://github.com/zaphoyd/websocketpp>

¹⁵<https://www.boost.org/>

genügen und die systemweite Verfügbarkeit der kompilierten boost-Bibliothek nicht garantiert werden kann, wird die Teilbibliothek `boost_system` statisch in die ausführbaren Datei `host` eingebunden.

Zuletzt werden über Compilerflags alle Kompilierfehler und -warnungen aktiviert sowie die POSIX-Thread-Bibliothek eingebunden und spezielle Flags für die Websocket-library und MPI gesetzt.

3.4.2 Mainfunktion und Initialisierung

Zur Initialisierung der Prozesse muss zunächst die MPI-Umgebung aktiviert und abgerufen werden. Dies geschieht für beide Programme gleich, über die Initialisierungsfunktion in Quelltext 12. Sie erwartet lediglich eine Beschreibung des Prozesses für den Log und eine Initialisierungsfunktion, die erst zurückkehrt, wenn das Programm abgeschlossen ist und MPI beendet werden soll. Die Funktion muss als Parameter den Rang bzw. die Id des aktuellen MPI-Prozesses und die Anzahl der initialisierten Prozesse entgegen nehmen.

Ein beispielhafter Aufruf ist in Quelltext 11 zu sehen. Damit wird MPI initialisiert und nach der erfolgreichen Initialisierung der eigentliche Host-Prozess über `Host::init` gestartet.

```

1 #include "init.h"
2 #include "Host.h"
3
4 int main(int argc, char *argv[])
5 {
6     return init(argc, argv, "Host", Host::init);
7 }
```

Quelltext 11: Initialisierung des Host-Prozesses in host.main.cpp

3.5 Host Funktionalitäten

3.5.1 Websocketverbindung

Direkt nach der Initialisierung des Host-Programms in Quelltext 13, wird ein separater Thread gestartet, der über Websocket Anfragen zur Berechnung einer Region entgegennimmt sowie ein Thread, der berechnete Regionen an den verbundenen Client übergibt. Die Methode `Host::start_server` initialisiert dabei lediglich den Websocketserver mit den Methoden zum Behandeln geöffneter und geschlossener Verbindungen und einer Methode um Nachrichten des Clients zu behandeln, `Host::handle_region_request`. Der zweite gestartete Thread führt die Methode `Host::send` aus. Zudem wird der Websocketserver mit `server.init_asio()` mit der Transport Policy "transport::asio" konfiguriert, sodass Multithreadzugriff auf Sende- und Empfangsmethoden problemlos möglich ist [2].

```

15 int init(int argc, char **argv, const char* type, void (*initFunc) (int
16   world_rank, int world_size)) {
17
18   MPI_Init(&argc, &argv);
19   int world_rank;
20   MPI_Comm_rank(MPI_COMM_WORLD, &world_rank);
21   int world_size;
22   MPI_Comm_size(MPI_COMM_WORLD, &world_size);
23   // Retreive the processor name to check if host and
24   // worker share a node
25   char* proc_name = new char[MPI_MAX_PROCESSOR_NAME];
26   int proc_name_length;
27   MPI_Get_processor_name(proc_name, &proc_name_length);
28   std::cout << type << ":" << world_rank << " of " << world_size <<
29   " on node " << proc_name << std::endl;
30
31   if (world_size < 2) {
32     std::cerr << "Need at least 2 processes to run. Currently have "
33     << world_size << std::endl;
34     MPI_Finalize();
35     return -1; // return with error
36   }
37   initFunc(world_rank, world_size);
38   MPI_Finalize();
39
40   return 0;
}

```

Quelltext 12: Initialisierung der MPI-Prozesse in init.cpp

```

382           fractal_str = "mandelbrot";
383       }
384       regionJSON.AddMember("fractal", Value().SetString(fractal_str,
385           strlen(fractal_str)), answer.GetAllocator());
385       regionJSON.AddMember("regionCount", region.regionCount, answer.
386           GetAllocator());
386
387       workerInfoJSON.AddMember("region", regionJSON, answer.
388           GetAllocator());
388
389       answer.AddMember("workerInfo", workerInfoJSON, answer.
390           GetAllocator());
390       answer.AddMember("data", rawDataJSON, answer.GetAllocator());
391       answer.AddMember("type", "regionData", answer.GetAllocator());
392
393       // Stringify reply

```

Quelltext 13: Starten des Websocketservers bei der Initialisierung des Host-Programmes in Host.cpp

Host::handle_region_request Die Methode versucht, den Inhalt der empfangenen Nachricht als JSON zu dekodieren und entnimmt die für das struct Region notwendigen Werte unter gleichem Namen dem Objekt, das unter dem Schlüssel "region" in der geprästen Anfrage gespeichert ist. Außerdem erwartet es unter dem Schlüssel "balancer" einen String, der den zu wählenden Lastbalancierer bestimmt und unter dem Schlüssel "type" den String "regionRequest". Mögliche Zeichenketten hierfür sind in den Klassen der Balancierer unter backend/src/balancer in der globalen Variable `Klassenname::NAME` gespeichert. Ein Beispiel für einen Namen kann in Quelltext 14 gefunden werden:

```
11 const std::string PredictionBalancer::NAME = "prediction";
```

Quelltext 14: Namensdefinition des PredictionBalancers

Ein Beispiel für eine gültige Regionsanfrage ist in Quelltext 15 zu finden. Einerseits wird hierbei eine Region in komplexen Koordinaten beschrieben, wobei der obere linke Punkt ($maxImag, minReal$) und der rechte untere Punkt ($minImag, maxReal$) in der komplexen Ebene einen zu berechnenden Bereich aufspannen. Da die reelle Ebene jedoch beliebig genau aufgelöst werden kann, muss zudem noch die Anzahl an Pixeln pro Seite des Rechteckes definiert werden, `width` und `height`. Wie in Abbildung 3 zu sehen, ist zudem der horizontale Offset und vertikale Offset die linke obere Koordinate der Region bezüglich der gesamten sichtbaren Anfrage in Pixeln (diese Werte gewinnen in den Regionsaufteilungen an Bedeutung). Der Wert `validation` ist technisch gesehen nicht mehr notwendig, wird aber mit dem Zoom-wert der Leafletkarte gefüllt um zu vermeiden dass Regionsdaten von zuvor berechneten Regionen falsch verwendet werden.

Nach dem Parsen der Nachricht wird die Region global festgelegt und beim korrekten Lastbalancierer eine Zerlegung der angefragten Region über `Balancer::balanceLoad` gestartet.

Jeder Region wird ein Worker zugewiesen. Dabei ist der Rang des Workers, der eine Region berechnen soll genau der Index der Region in dem zurückgegebenen Array. Ist ein Worker nicht verfügbar, so werden sein und alle folgenden Ränge um eins erhöht (siehe Quelltext 16). Damit kann der WebSocketprozess unabhängig von der tatsächlichen Verteilung den Rang des berechnenden Worker-Prozesses bestimmen und in der Antwort an den Client zu der Aufteilung der Prozesse einfügen. Die Struktur und eine gültige Antwort des Websocketervers kann Quelltext 17 entnommen werden.

Nachdem die Aufteilung als Antwort auf die Anfrage dem WebSocketprozess bereitgestellt wurde, werden die Teilregionen in eine per Mutexlock-gesicherte Datenstruktur gelegt. Der MPI verwendende Thread, der diese Regionen anschließend an die Worker sendet wird über das Setzen des booleschen Wertes `mpi_set_regions` auf `true` darüber informiert, dass neue Regionen zum versenden zur Verfügung stehen.

Indem die Regionsaufteilung zuerst an das Frontend und anschließend an die Worker gesendet wird, wird sichergestellt, dass das Frontend alle empfangenen Regionsdaten korrekt der angefragten Region zuordnen kann. Dabei wird zwar Rechenzeit verschenkt, jedoch steigt durch die Erstellung sehr kleiner oder leerer Teilregionen die Wahrscheinlichkeit,

```

1  {
2      "type": "regionRequest",
3      "region": {
4          "minReal": -0.251953125,
5          "maxImag": -0.8388671875,
6          "maxReal": -0.2216796875,
7          "minImag": -0.8505859375,
8          "width": 1984,
9          "height": 768,
10         "hOffset": 0,
11         "vOffset": 0,
12         "validation": 8,
13         "guaranteedDivisor": 64,
14         "maxIteration": 1019
15     },
16     "balancer": "naiveRecursive",
17     "fractal": "mandelbrot"
18 }

```

Quelltext 15: Eine gültige Anfrage einer Region in JSON

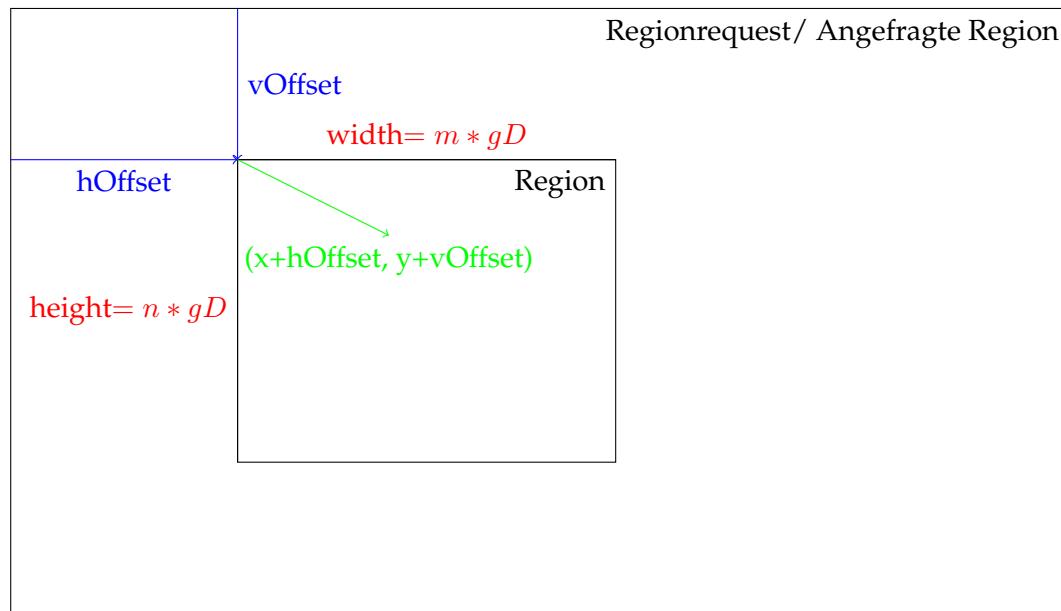


Abbildung 3: Konzept der Koordinaten in den Regionsobjekten. Alle Koordinaten beziehen sich auf die Darstellungsebene und sind daher in Pixeln.

```

231 }
232
233 Document reply;
234 reply.SetObject();
235
236 reply.AddMember("type", "region", reply.GetAllocator());
237 reply.AddMember("regionCount", regionCount, reply.GetAllocator());
238 reply.AddMember("balancerTime", Value().SetInt64(balancerTime), reply
    .GetAllocator());
239
240 Value workers;

```

Quelltext 16: Algorithmus zur Zuordnung von Regionen auf Worker in Host.cpp

lichkeit, dass ein Arbeiter mit seiner Region zu früh abgeschlossen ist. Würde dann dessen Region vor der Gesamtaufteilung beim Frontend ankommen, besteht die Gefahr, dass es die Daten verwirft.

Host::send Während ein Thread das Empfangen von Nachrichten übernimmt, behandelt diese Methode von den Workern fertig berechnete Regionen. Er versendet in einer Dauerschleife Regionsdaten an den aktuell verbundenen Client. Nach jedem Durchlauf oder wenn der Thread per `notify` (oder auch durch mögliche andere Nebeneffekte) aufgeweckt wird, überprüft er auf das Vorhandensein neuer Regionen, wählt die erste aus und entfernt sie aus der Datenstruktur. Nachdem das Lock auf die geteilte Datenstruktur gelöst wurde, werden die Regionsdaten JSON codiert versendet. Ein Beispiel für versendete Regionsdaten kann Quelltext 18 entnommen werden. Dabei wird der Punkt (x, y) in der gesendeten Region (Punkt $(x+hOffset, y+vOffset)$ in der angefragten Region) im Datenarray an Index $i = x + y * width$ gespeichert. Ist keine Region in der Datenstruktur abgelegt wird per `wait` auf eine Änderung gewartet. Mit Hilfe der `condition_variable`¹⁶ `Host::mpi_to_websocket_result_available` nutzt sie die C++11 nativen mutex-Mechanismen um über das Vorhandensein neuer Regionen informiert zu werden.

3.6 Lastbalancierung

Um die Mandelbrotmenge effizient parallel zu berechnen, muss die Last gleichmäßig auf die Worker verteilt werden. Die Aufgabe der Lastbalancierung besteht darin zu einer gegebenen Region und einer Anzahl von Workern eine solche Unterteilung in sogenannte Teilregionen zu finden. Wichtig dabei ist, dass der garantierte Teiler von Höhe und Breite der Teilregionen dem der angeforderten Region entspricht. Eine Tile (ein Bereich mit Breite und Höhe gleich dem garantierten Teiler¹⁷, die Bezeichnung *Tile* kommt aus dem Frontend) muss also als atomare Einheit betrachtet werden, da es sonst im Frontend zu Schwierigkeiten bei der Darstellung kommt. Die Klassenstruktur

¹⁶https://en.cppreference.com/w/cpp/thread/condition_variable

¹⁷Eine Region lässt sich also immer in eine ganzzahlige Anzahl von Tiles aufteilen, vgl. Abbildung 5

```
1  {
2      "type": "region",
3      "regionCount": 37,
4      "regions": [
5          {
6              "rank": 1,
7              "computationTime": 0,
8              "region": {
9                  "minReal": -0.251953125,
10                 "maxImag": -0.8408203125,
11                 "maxReal": -0.24609375,
12                 "minImag": -0.8427734375,
13                 "width": 384,
14                 "height": 128,
15                 "hOffset": 0,
16                 "vOffset": 0,
17                 "maxIteration": 1019,
18                 "validation": 8,
19                 "guaranteedDivisor": 64
20             }
21         },
22         {
23             "rank": 2,
24             "computationTime": 0,
25             "region": {
26                 "minReal": -0.251953125,
27                 .....
28             },
29             {
30                 "rank": 37,
31                 "computationTime": 0,
32                 "region": {
33                     "minReal": -0.2275390625,
34                     "maxImag": -0.84765625,
35                     "maxReal": -0.2216796875,
36                     "minImag": -0.8486328125,
37                     "width": 384,
38                     "height": 64,
39                     "hOffset": 1600,
40                     "vOffset": 448,
41                     "maxIteration": 1019,
42                     "validation": 8,
43                     "guaranteedDivisor": 64
44                 }
45             }
46         }
47     ]
48 }
```

Quelltext 17: Ausschnitt aus einer gültigen Antwort auf die Region aus Quelltext 15 in JSON

```

1  {
2      "type": "regionData",
3      "workerInfo": {
4          "rank": 3,
5          "computationTime": 1120852,
6          "region": {
7              "minReal": 0.33984375,
8              "maxImag": -0.583984375,
9              "maxReal": 0.400390625,
10             "minImag": -0.5859375,
11             "width": 1984,
12             "height": 64,
13             "hOffset": 0,
14             "vOffset": 128,
15             "maxIteration": 1019,
16             "validation": 7,
17             "guaranteedDivisor": 64
18         }
19     },
20     "data": [22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22,
21     22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22,
22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22,
22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22,
22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22, 22,
22, 22, 22, 23, 23, 23, 23, 23, 23, 23, 23, 23, 23,
23, 23, 23, 23, 23, 23, 23, 23, 23, 23, 23, 23, 23,
23, 23, 23, 23, 23, 23, 23, 23, 23, 23, 23, 23, 23,
23, 23, 23, 23, 23, 23, 23, 23, 23, 23, 23, 23, 23,
24, 24, 24, 24, 24, 24, 24, 24, 24, 24, 24, 24, 24,
24, 24, 24, 24, 24, 24, ...]
21 ]

```

Quelltext 18: Ausschnitt aus den Daten einer versendeten Teilregion. Punkt (x,y) liegt in "data" an Index $i = x + y * width$.

der Lastbalancierer entspricht dem Strategy-Pattern¹⁸. So kann der Balancierer zur Laufzeit leicht gewechselt werden und auch die Erweiterung des Projekts um eine weitere Strategie gestaltet sich einfach. Was dabei genau beachtet werden muss findet sich im Teil Erweiterung.

Damit die Unterschiede zwischen guter und schlechter Lastverteilung deutlich werden, wurden hier verschiedene Strategien zur Lastbalancierung implementiert.

3.6.1 Naive Strategie

Bei der naiven Strategie (zu finden in den Klassen `NaiveBalancer` und `RecursiveNaiveBalancer`) wird versucht den einzelnen Workern etwa gleich große Teilregionen zuzuweisen. Dies geschieht allerdings ohne Beachtung der eventuell unterschiedlichen Rechenzeiten innerhalb der Teilregionen. Die naive Strategie wurde hier in einer nicht-rekursiven und einer rekursiven Variante implementiert.

Nicht-rekursive Variante Zur nicht-rekursiven Aufteilung wird zuerst die Anzahl der zu erstellenden Spalten und Zeilen berechnet. Dazu wird der größte Teiler der Anzahl der Worker bestimmt. Dieser gibt die Anzahl der Spalten an, das Ergebnis der Division ist die Anzahl der Zeilen. Damit ist sichergestellt, dass die Region in die richtige Menge von Teilregionen unterteilt wird.

Als nächstes wird die Breite und Höhe der Teilregionen berechnet. Hierbei ist wichtig, dass der garantierte Teiler erhalten wird. Die Breite berechnet sich also durch:

$$\frac{\text{region.width}}{\text{region.guaranteedDivisor} * \text{nodeCount}} * \text{region.guaranteedDivisor}$$

Dabei ist `nodeCount` die Anzahl der Worker und `region` die zu unterteilende Region. Es ist zu beachten, dass es sich hier um eine Ganzzahldivision handelt, deren Rest angibt, wie viele Teilregionen um `region.guaranteedDivisor` breiter sind. Die Höhe berechnet sich analog.

Bevor die eigentliche Aufteilung beginnt werden noch die Deltas für Real- und Imaginärteil bestimmt. Diese geben an, wie breit bzw. hoch der Bereich der komplexen Ebene ist, den ein Pixel der Region überdeckt. Die Deltas können über Methoden der Klasse `Fractal` berechnet werden.

Zur Aufteilung wird nun mittels zweier verschachtelter Schleifen über die Zeilen und Spalten iteriert. Die benötigten Start- und Endpunkt der Teilregionen (also die linke obere Ecke und die rechte untere Ecke auf der komplexen Ebene) können nun mithilfe der Schleifenzähler und der Deltas bestimmt werden. Zusätzlich wird noch der vertikale und horizontale Offset der Teilregion vom Startpunkt der Eingaberegion abgespeichert. Diese Information ermöglicht es die Region im Frontend einfach anzuzeigen.

Falls die aktuell betrachtete Teilregionen zu den Breiteren und/oder Höheren (s.o.) gehört, müssen alle Werte entsprechend angepasst werden. Die letzte Teilregion einer

¹⁸https://sourcemaking.com/design_patterns/strategy

Spalte bzw. Zeile wird immer so gewählt, dass sie auf jeden Fall mit dem Rand der Eingaberegion abschließt.

Die Teilregionen werden in einem Ergebnisarray gespeichert, welches dann zurückgegeben wird.

Rekursive Variante Die Grundidee der rekursiven Balancierung ist, die Region solange zu halbieren, bis man genug Teile für jeden Worker hat. Dies funktioniert sehr gut, wenn die Anzahl der Worker eine 2er-Potenz ist. Wenn das nicht der Fall ist, so müssen für einige Worker die Regionen öfters geteilt werden als für andere. Die Anzahl der Blätter des Rekursionsbaumes (hier ein Binärbaum) muss also der Anzahl der Worker entsprechen.

Um die Werte, die während der rekursiven Auswertung benötigt werden, einfach weiterreichen zu können wurde die Struktur `BalancingContext` definiert. Diese beinhaltet einen Zeiger auf das Ergebnisarray (`result`) und den aktuellen Index (`resultIndex`) in dieses. Zusätzlich ist in `partsLeft` gespeichert, wie viele Teilregionen der jeweilige Rekursionsschritt noch erzeugen muss. Auch die Deltas für Real- und Imaginärteil sind in der Struktur abgelegt, um wiederholte Berechnungen zu vermeiden.

Aus `partsLeft` kann auch die Abbruchbedingung der Rekursion gefolgert werden:

$$\text{partsLeft} = 1 \quad (2)$$

Ist die Abbruchbedingung (2) erfüllt, so genügt es die übergebene Region in das Ergebnisarray einzutragen und `resultIndex` zu inkrementieren. Ansonsten muss die Region halbiert werden. Ist die Region vertikal oder horizontal nicht mehr teilbar (d.h. `region.width` bzw. `region.height ≤ region.guaranteedDivisor`), so wird in die andere Richtung geteilt. Kann die Region in beide Richtungen geteilt werden, so wird parallel zur kürzeren Seite geteilt. Dies gibt dem Lastbalancierer mehr Möglichkeiten die Trennlinie zwischen den Teilregionen zu setzen, was zu einer genaueren Teilung führt. Wenn die Region unteilbar ist, so muss eine leere Region erzeugt werden.

Die beiden Hälften berechnen sich wie bei der Aufteilung auf zwei Worker mit der nicht-rekursiven Strategie. Dann wird die Funktion für jede Hälfte rekursiv aufgerufen, wobei `partsLeft` entsprechend halbiert wird.

3.6.2 Strategie mit Vorhersage

Bei dieser Strategie (zu finden in den Klassen `PredictionBalancer` und `RecursivePredictionBalancer`) basiert die Aufteilung der Region auf einer Vorhersage über die Rechenzeit. Die Teilregionen werden so gewählt, dass sie, entsprechend der Vorhersage, etwa einen ähnlichen Rechenaufwand haben.

Bestimmung der Vorhersage Die Vorhersage (`struct Prediction`) wird von der Klasse `Predictor` angestellt. Dazu wird die Region in einer sehr viel geringeren Auflösung berechnet. Die benötigte Anzahl an Iterationen wird jeweils pro Tile abgespeichert. So wird sichergestellt, dass der garantierte Teiler auch nach der Aufteilung noch gilt, da

die Balancierer die Vorhersage Eintrag für Eintrag verarbeiten. Die Genauigkeit der Vorhersage kann über das Attribut `predictionAccuracy` gesteuert werden:

- $\text{predictionAccuracy} > 0$: $(\text{predictionAccuracy})^2$ Pixel werden pro Tile berechnet. Die Summe der Iterationen für die einzelnen Pixel ergibt die Vorhersage für die Tile.
- $\text{predictionAccuracy} < 0$: Für $(\text{predictionAccuracy})^2$ Tiles wird ein Pixel in der Vorhersage berechnet. Es erhalten also mehrere Tiles dieselbe Vorhersage.
- $\text{predictionAccuracy} = 0$: Unzulässig, es wird ein Null-Pointer zurückgegeben.

Es ist wichtig eine gute Balance zwischen Güte und Geschwindigkeit der Vorhersage zu finden. Zusätzlich beinhaltet die Vorhersage die Summen der benötigten Iterationen pro Spalte und Zeile, sowie die Gesamtsumme. Auch die Deltas für Real- und Imaginärteil pro Tile und die Anzahl der Zeilen und Spalten werden angegeben.

Auch die Strategie mit Vorhersage wurde in einer rekursiven und in einer nicht-rekursiven Variante implementiert.

Nicht-rekursive Variante Für die nicht-rekursive Variante wird zuerst die benötigte Anzahl an Zeilen und Spalten bestimmt. Dies geschieht genauso wie bei der naiven Strategie.

Die erzeugten Teilregionen sollen in etwa den gleichen Rechenaufwand haben. Dieser berechnet sich durch:

$$\text{desiredN} = \frac{nSum}{nodeCount} \quad (3)$$

Dabei ist `nSum` die Gesamtsumme der Vorhersage und `nodeCount` wieder die Anzahl der Worker.

Danach wird die Region erst in Spalten aufgeteilt und in einem zweiten Schritt wird dann die horizontale Unterteilung in Teilregionen vorgenommen.

Zur Aufteilung wird über die Spaltensummen in der Vorhersage iteriert (vgl. Quelltext 19). Diese werden aufaddiert und bilden so den Zähler `currentN`. Sobald $\text{currentN} \geq \text{desiredN}$ gilt oder für alle restlichen Spalten nur noch je ein Eintrag in den Spaltensummen vorhanden ist, wird eine Spalte abgeschlossen. Dazu werden `maxReal` und `width` aus den Zählern berechnet. Es ist wichtig `maxReal` immer neu aus `region.minReal` zu berechnen, anstatt nur das Delta aufzuaddieren, da sich sonst der Fehler, der bei Fließkommaaddition unvermeidbar ist, auch mit aufaddiert. `minReal` und `hOffset` stehen bereits in der Region `tmp`, die Werte wurden bei der Berechnung der vorhergehenden Spalte bereits gesetzt. Jetzt wird `tmp` für die nächste Spalte vorbereitet, das heißt `tmp.minReal` wird auf `tmp.maxReal` gesetzt und `tmp.hOffset` wird um `tmp.width` erhöht. Ersteres vermeidet das Entstehen von Lücken zuverlässig. Außerdem wird `desiredN` für die verbleibenden Spalten nach (3) neu berechnet und die Zähler werden zurückgesetzt. Bevor die Aufteilung der Spalte in Teilregionen startet, wird eine Kopie der Vorhersage erstellt, die nur die Werte für die aktuelle Spalte enthält. Das Aufteilen einer Spalte in Teilregion geschieht analog zum Aufteilen in Spalten.

Die letzte Spalte wird gesondert behandelt: Sie muss so gewählt werden, dass sie den gesamten Rest der Eingaberegion abdeckt, ansonsten können Lücken entstehen. Dies gilt genauso bei der Unterteilung der einzelnen Spalten.

Rekursive Variante Die rekursive Variante der Strategie mit Vorhersage verwendet dasselbe Rekursionsschema wie ihr naives Gegenstück. Die Abbruchbedingung ist also wie in (2). Auch die Entscheidung, ob horizontal oder vertikal geteilt werden soll, wird auf die gleiche Art und Weise gefällt. Der Unterschied zwischen den beiden Strategien liegt also hauptsächlich in den beiden Methoden zur Aufteilung.

Bei dieser Strategie werden die Regionen nicht einfach halbiert, sondern in zwei Teile aufgeteilt, die laut der Vorhersage ähnlich rechenintensiv sind. Dazu wird ähnlich vorgegangen, wie bei der nicht-rekursiven Variante für die Aufteilung auf zwei Worker. Deshalb profitiert diese Strategie auch besonders davon, dass immer parallel zur kürzeren Seite geteilt wird. Die Vorhersage ist in diese Richtung nämlich feingliedriger, da weniger Tiles der Vorhersage zu einer Spalte bzw. Zeile zusammengefasst werden müssen als wenn parallel zur längeren Seite aufgeteilt werden würde. Allerdings wird hier, wenn möglich, sichergestellt, dass beide Teilregionen groß genug sind um jeweils auf $\frac{\text{context.partsLeft}}{2}$ Worker aufgeteilt zu werden. Es ist hierbei auch wichtig die Vorhersage so zu teilen, dass es für jede Hälfte eine Vorhersage gibt, die dann an den rekursiven Aufruf übergeben werden kann.

3.6.3 Erweiterung

Da die Lastbalancierung nach dem Strategy-Pattern realisiert ist, gestaltet sich die Erweiterung um eine neue Balancierungsstrategie recht einfach. Zuerst muss eine Unterklasse von `Balancer` (Quelltext 20) erstellt werden, um ein gemeinsames Interface zu erzwingen und somit die polymorphe Nutzung der neuen Klasse zu ermöglichen.

Danach wird die neue Strategie über die Methode `BalancerPolicy::chooseBalancer` verfügbar gemacht. Dazu muss die neue Strategie mithilfe der statischen Variablen `Klassenname::NAME` benannt werden. `BalancerPolicy` muss nun so erweitert werden, dass, bei Eingabe des vorher festgelegten Namens, ein neues Objekt der entsprechenden Klasse zurückgegeben wird. In `BalancerPolicy` kann auch die Genauigkeit der Vorhersage für die oben aufgeführten Strategien festgelegt werden.

Bedingungen an `Balancer::balanceLoad` Bei der Eingabe von `region` und `nodeCount` erfüllt ein korrekter Rückgabewert `subregions` die folgenden Bedingungen:

- `subregions` ist ein Zeiger auf ein Array mit `nodeCount` Elementen vom Typ `Region`
- Die Regionen in `subregions` sind eine Partitionierung von `region`, d.h. sie überschneiden sich nicht und ihre Vereinigung ergibt genau `region`
- Für jede Region `subregion` in `subregions` gilt:
 - `guaranteedDivisor`, `validation`, `maxIteration` und `fractal` sind in `region` und `subregion` gleich

```

1  Region tmp = region;
2
3  int currentN = 0;
4  int currentCol = 0;
5  int cumulativeN = 0; // Needed to update desiredN
6  int usedPredictionCols = 0; // Needed to determine resolution
7
8  for (int i = 0; i < prediction->predictionLengthX; i++) {
9      if (currentCol == cols - 1) {
10          // Take the rest
11          tmp.maxReal = region.maxReal;
12          tmp.width = region.width - region.guaranteedDivisor * i;
13
14          // Split this column (tmp) and write to result (left out)
15
16          currentCol++;
17          // End the loop
18          break;
19      }
20
21      // Add nColSums entry to currentN
22      currentN += prediction->nColSums[i];
23      // Increment usedPredictionCols
24      usedPredictionCols++;
25
26      // Reached 1/cols of nSum or there is only one piece of
27      // prediction left for each remaining col
28      if (currentN >= desiredN || prediction->predictionLengthX - (i +
29          1) <= cols - currentCol) {
30          tmp.maxReal = region.minReal + (i + 1) * prediction->
31              deltaReal;
32          tmp.width = region.guaranteedDivisor * usedPredictionCols;
33
34          // Split this column (tmp) and write to result (left out)
35
36          // Prepare tmp for next col
37          tmp.minReal = tmp.maxReal;
38          tmp.hOffset += tmp.width;
39
40          // Update cumulativeN
41          cumulativeN += currentN;
42          // Increment currentCol
43          currentCol++;
44          // Update desiredN --> this should reduce the difference of n
45          // between the cols
46          desiredN = (prediction->nSum - cumulativeN) / (cols -
47              currentCol);
48          // Reset currentN
49          currentN = 0;
50          // Reset usedPredictionCols
51          usedPredictionCols = 0;
52      }
53  }
54 }
```

Quelltext 19: Aufteilung in Spalten (Auszug)

```

1 #include "Region.h"
2
3 class Balancer {
4     public:
5         virtual Region* balanceLoad(Region region, int nodeCount) = 0;
6         virtual ~Balancer();
7 };

```

Quelltext 20: Das gemeinsame Interface der Lastbalancierung

- subregion.guaranteedDivisor teilt subregion.width und subregion.height ohne Rest
- subregion.hOffset und subregion.vOffset sind so gesetzt, dass sie den Abstand der oberen linken Ecke von subregion zur oberen linken Ecke von region angeben
- Die Deltas für die komplexen Werte sind unverändert, d.h. die Größe des Bereiches der komplexen Ebene, der von einem Pixel abgedeckt wird, ist unverändert

Ob diese Bedingungen erfüllt sind kann mit dem Test in BalancerTest überprüft werden.

3.7 Kommunikation der Prozesse per MPI

Das Message Passing Interface (MPI) wird ausschließlich im Backend zur Kommunikation zwischen dem Host und den Workern verwendet.

MPI und Threads Da sowohl im Host, als auch in den Workern mehrere Threads arbeiten, muss die Kompatibilität von MPI mit Threads genau betrachtet werden. Laut der offiziellen MPI Dokumentation¹⁹ müssen die konkreten Implementierungen von MPI keinerlei Threads unterstützen, die meisten bekannten Implementierungen (wie beispielsweise Open MPI²⁰) tun dies aber, falls sie entsprechend konfiguriert wurden.

Es wurde besonders darauf geachtet, dass nur ein Thread pro Prozess MPI-Aufrufe tätigt, wodurch die Thread-Umgebung mit MPI_THREAD_FUNNELED initialisiert werden kann. Dadurch kann MPI einige Optimierungen durchführen, die nicht möglich wären, wenn mehrere Threads MPI-Aufrufe tätigen. Zudem sind die meisten MPI Implementierungen noch nicht auf eine performante Umsetzung von mehreren Threads ausgelegt, weshalb das Thread-Level so niedrig wie möglich gehalten werden sollte.

Busy-Waiting von MPI Da MPI grundsätzlich auf Höchstleistung ausgelegt ist, werden die Empfangsoperationen mit Busy-Waiting umgesetzt. Das führt einerseits dazu, dass ankommende Nachrichten ohne Verzögerung empfangen werden und die Bearbeitung der Daten sofort starten kann. Andererseits führt das aber zu einer 100-Prozentigen

¹⁹<https://www.mpi-forum.org/docs/mpi-3.1/mpi31-report.pdf>

²⁰https://www.open-mpi.org/doc/v3.1/man3/MPI_Init_thread.3.php

Auslastung des Rechenkerns, was andere Prozesse von der Durchführung ihrer Arbeit abhalten kann und zu einem erhöhten Stromverbrauch führt.

Im Fall des blockierenden MPI_Recv wird solange aktiv ohne Pause getestet, ob eine Nachricht empfangen wurde, bis dies auch wirklich geschehen ist. Falls eine nicht-blockierende Empfangsoperation mit MPI_Irecv gestartet wird, muss diese anschließend auch abgeschlossen werden. Dazu kann einerseits MPI_Wait dienen, das solange wartet, bis die Empfangsoperation abgeschlossen ist. Hierzu wird ebenfalls Busy-Waiting nutzt. Andererseits kann auch MPI_Test genutzt werden, was nur überprüft, ob die Empfangsoperation abgeschlossen ist ohne auf deren Abschluss zu warten. Auch hier gibt es keine andere Möglichkeit, als immer wieder (beispielsweise in einer Schleife) MPI_Test aufzurufen. Der einzige Vorteil besteht darin, dass zwischen diesen wiederholten Aufrufen andere Arbeit erledigt oder der Prozess für eine gewisse Zeit schlafen gelegt werden kann. Mit MPI_Probe bzw. MPI_Iprobe verhält es sich ähnlich wie mit MPI_Recv bzw. MPI_Test. Also wird auch hier Busy-Waiting eingesetzt.

In der Implementierung wurde deshalb im Host und im Worker eine nicht-blockierende Empfangsmethode gewählt, die den Thread für x Millisekunden schlafen legt, bevor ein erneuter Empfangsversuch gestartet wird. Die damit einhergehende Verzögerung verfälscht das Ergebnis nicht schwerwiegend, da die Berechnung einer Region für gewöhnlich deutlich länger als y Millisekunden benötigt.

Nutzbarkeit der Worker definieren Es besteht die Möglichkeit, explizit zu definieren ob ein Worker Rechenaufträge bekommen soll oder nicht. Hierzu existiert im Host das globale Boolean-Array `usable_nodes`. Ein Prozess mit Rang x ist benutzbar, wenn `usable_nodes` am Index x `true` ist. Nicht benutzbar ist er, wenn die Variable auf `false` gesetzt ist. Zudem existiert noch die globale Variable `usable_nodes_count`, die angibt wie viele Worker benutzbar sind. Genutzt wird dieses Feature, falls beim Initialen Test aller Worker Worker als nicht benutzbar eingestuft werden.

Initialer Test aller Worker Bevor Rechenaufträge an die Worker weitergeleitet werden, wird zunächst jeder Worker einzeln getestet. Dies dient auch dazu, den Workern den Rang des Hosts zu übermitteln.

Dazu sendet der Host mittels der nicht-blockierenden, synchronen Sendeoperation `MPI_Issend` einen Test-Wert an alle Worker. Durch die synchrone Eigenschaft wird die Operation erst abgeschlossen, wenn eine passende Empfangsoperation gestartet und der Sendeoperation zugeordnet wurde. Es wurde eine nicht-blockierende Sendeoperation gewählt, um den Test für alle Worker parallel ausführen zu können. Der Source-Code ist in Quelltext 21 zu finden.

Wurden alle Sendeoperationen gestartet, muss auf deren Abschluss gewartet werden. Falls nun ein Worker nicht wie erwartet reagiert und die Empfangsoperation nicht durchführt, muss das Warten auf den Abschluss der Sendeoperation abgebrochen werden können. Deshalb wird `MPI_Testsome` in einer Endlosschleife genutzt, die nur abbricht falls alle Sendeoperationen erfolgreich waren (alle `MPI_Requests` sind `MPI_REQUEST_NULL`, wodurch `MPI_Testsome` in `outcount` `MPI_UNDEFINED` zurück-

gibt) oder ein Timer abgelaufen ist. Falls eine oder mehrere Sendeoperationen innerhalb eines Schleifendurchlaufs erfolgreich abgeschlossen wurden, wird deren MPI_Request auf MPI_REQUEST_NULL gesetzt um dies explizit zu zeigen. Sie werden in den nächsten Schleifendurchläufen von MPI_Testsome ignoriert. In Quelltext 22 ist der entsprechende Code zu finden.

Nachdem die Schleife abgebrochen wurde, muss noch überprüft werden, welche Sendeoperationen erfolgreich waren und welche nicht. War die Operation erfolgreich, wird der entsprechende Worker als nutzbar eingestuft. Falls nicht, wird die noch laufende Sendeoperation mit MPI_Cancel abgebrochen und der Worker als nicht benutzbar eingestuft. Der Code kann in Quelltext 23 eingesehen werden.

```

428 // Test if all cores are available
429 // This also allows the Workers to get the rank of the Host
430 MPI_Request test_requests[usable_nodes_count];
431 MPI_Status test_status[usable_nodes_count];
432 // Send test messages to every Worker
433 for (int rank = 0 ; rank < world_size ; rank++) {
434     if (rank != world_rank) {
435         // Skip Host
436         int acc = 0;
437         if (rank > world_rank) {
438             acc = 1;
439         }
440         int test_send = rank;
441         int ierr = MPI_Issend((const void *) &test_send, 1, MPI_INT,
442                               rank, 10, MPI_COMM_WORLD, &test_requests[rank - acc]);
443         // Error handling
444         if (ierr != MPI_SUCCESS){
445             std::cerr << "Error on MPI_Issend to worker " << rank <<
446             " on test send: " << std::endl;
447             char err_buffer[MPI_MAX_ERROR_STRING];
448             int resultlen;
449             MPI_Error_string(ierr, err_buffer, &resultlen);
450             fprintf(stderr, err_buffer);
451         }
452         // Error handling - end
453     }
454 }
```

Quelltext 21: Starten der Sendeoperation zum Testen der Worker

3.7.1 Genereller Aufbau der MPI-Kommunikation

Im Folgenden wird kurz der generelle Aufbau der MPI-Kommunikationsroutinen im Host und in den Workern erklärt.

MPI-Kommunikation im Host Die essenziellen Teile der MPI-Kommunikation des Hosts, also das Senden von Rechenaufträgen und das Empfangen der berechneten Daten, befinden sich in einer gemeinsamen Endlosschleife. Dabei wird immer zuerst überprüft,

```

453 // Start timer
454 std::chrono::high_resolution_clock::time_point test_time_start = std
455   ::chrono::high_resolution_clock::now();
456 unsigned long test_time = 0;
457 // Check if every Worker has started its receive operation
458 int *array_of_indices = new int[usable_nodes_count];
459 do {
460     int outcount;
461     int ierr = MPI_Testsome(usable_nodes_count, test_requests, &
462       outcount, array_of_indices, test_status);
463     // Error handling
464     if (ierr != MPI_SUCCESS){
465         for (int i = 0 ; i < usable_nodes_count ; i++) {
466             ierr = test_status[i].MPI_ERROR;
467             if (ierr != MPI_SUCCESS) {
468                 std::cerr << "Error on MPI_Testsome with index " << i
469                   << " on test send: " << std::endl;
470                 char err_buffer[MPI_MAX_ERROR_STRING];
471                 int resultlen;
472                 MPI_Error_string(ierr, err_buffer, &resultlen);
473                 fprintf(stderr, err_buffer);
474             }
475         }
476     }
477     // Error handling - end
478     // Every send operation was successful
479     if (outcount == MPI_UNDEFINED) {
480         std::cout << "Tests successful. Break test loop." << std::
481           endl;
482         break;
483     }
484     // One or more send operations were successful. Set their
485     // MPI_Request to MPI_REQUEST_NULL
486     if (outcount != 0) {
487         for (int i = 0 ; i < outcount ; i++) {
488             test_requests[array_of_indices[i]] = MPI_REQUEST_NULL;
489         }
490     }
491     // Check how much time has passed
492     std::chrono::high_resolution_clock::time_point test_time_end =
493       std::chrono::high_resolution_clock::now();
494     test_time = std::chrono::duration_cast<std::chrono::microseconds>(
495       (test_time_end - test_time_start).count());
496 } while (test_time < 1000000);
497 delete [] array_of_indices;

```

Quelltext 22: Warten auf den Abschluss aller Sendeoperationen des Workertests

ob neue Rechenaufträge an die Worker zu senden sind. Gegebenenfalls werden die Sendeoperationen durchgeführt. Anschließend wird überprüft, ob berechnete Daten empfangen werden können. Ist das der Fall, so wird die Empfangsoperation durchgeführt, die Daten reorganisiert und über eine gemeinsame Datenstruktur an einen

```

491 // Update usable_nodes and usable_nodes_count according to the test
492 // results
493 for (int rank = 0 ; rank < world_size ; rank++) {
494     if (rank != world_rank) {
495         // Skip Host.
496         int acc = 0;
497         if (rank > world_rank) {
498             acc = 1;
499         }
500         if (test_requests[rank - acc] != MPI_REQUEST_NULL) {
501             usable_nodes[rank] = false;
502             usable_nodes_count--;
503             // Cancel uncompleted send operations
504             MPI_Cancel(&test_requests[rank - acc]);
505             MPI_Status cancel_status;
506             MPI_Wait(&test_requests[rank - acc], &cancel_status);
507             int cancel_flag;
508             MPI_Test_cancelled(&cancel_status, &cancel_flag);
509             if (cancel_flag == true) {
510                 std::cout << "Host: Worker " << rank << " has NOT
511                     started his receive operation. This Worker is NOT
512                     usable. Cancel was successful." << std::endl;
513             } else {
514                 std::cout << "Host: Worker " << rank << " has
515                     started his receive operation to late. This
516                     Worker is NOT usable. Cancel was NOT successful."
517                     << std::endl;
518             }
519             std::cout << "Host: There are " << usable_nodes_count << " usable
520             Worker." << std::endl;

```

Quelltext 23: Einstufung der Worker als nutzbar bzw. nicht nutzbar entsprechend des Testergebnisses

websocket-Thread weitergeleitet, der die Informationen an das Frontend reicht. Nun wird die Schleife von neuem begonnen. Es wird also sowohl für das überprüfen, ob neue Rechenaufträge vorhanden sind, als auch für das Empfangen der berechneten Daten Busy-Waiting eingesetzt.

MPI-Kommunikation im Worker Auch hier wird das Empfangen der Rechenaufträge und das Senden der berechneten Daten in einer Endlosschleife bewerkstelligt. Zu Beginn wird so lange gewartet, bis ein neuer Rechenauftrag empfangen wurde. Direkt im Anschluss wird die Berechnung der empfangenen Region gestartet, wobei während der Kalkulation auf neu ankommende Rechenaufträge gelauscht wird. Ist ein neuer

Auftrag zu empfangen, so wird die laufende Berechnung abgebrochen und die Schleife von vorne gestartet. Falls die Berechnung nicht unterbrochen wurde, werden die Daten organisiert und an den Host geschickt. Nun beginnt die Schleife von vorne. Es ist auch hier zu erkennen, dass Busy-Waiting für das Empfangen von neuen Rechenaufträgen eingesetzt wird.

3.7.2 Übertragung neuer Rechenaufträge vom Host an die Worker

Um neue Rechenaufträge an die Worker zu übertragen, werden im Host und in den Workern Persistent Communication Requests verwendet. Das hat den Vorteil, dass der Kommunikationsoverhead zwischen dem Prozess und dem Kommunikationscontroller reduziert wird. Die Nutzung dieser Persistent Communication Requests ist möglich, da immer die selbe Datenmenge an die selben Empfänger gesendet wird bzw. vom selben Absender (das ist hier der Host) empfangen wird.

Zur Übertragung der neuen Rechenaufträge wird das Region-Struct verwendet, welches bereits durch einen Websocket-Thread ausgefüllt wurde.

Initialisierung der Persistent Communication Requests Um die Persistent Communication Requests nutzen zu können, müssen diese zunächst Initialisiert werden.

Im Host werden hierzu ein Array mit MPI_Request, ein Array mit MPI_Status und ein Array mit Region erstellt. So bekommt jeder Prozess seinen eigenen Request, Status und Puffer für die zu sendende Region. Der Index, an dem sich diese Objekte befinden ist immer der von MPI zugewiesene Rang des Prozesses. Anschließend wird die eigentliche Initialisierung der Persistent Communication Requests durch einen Aufruf von MPI_Send_init für jeden Prozess durchgeführt, wobei als Tag der Kommunikation die Zahl 1 gewählt wurde. Als Kommunikationsmodus wird eine nicht-blockierende Standardsendeoperation gewählt. Durch diesen Kommunikationsmodus wird die Senden-Operation nur gestartet, d.h. der Aufruf kehrt unter Umständen zurück, bevor die Sendeoperation abgeschlossen ist. Dadurch wird ein paralleles, möglichst schnelles Senden aller Rechenaufträge gewährleistet. Mehr zur Durchführung des Sendens ist im nächsten Paragraphen zu finden. Die genaue Implementierung der Initialisierung ist in Quelltext 24 zu sehen.

Im Worker werden ebenfalls jeweils ein MPI_Request, ein MPI_Status und ein Region Objekt erstellt. Dann wird wieder der Persistent Communication Request durch einen Aufruf von MPI_Recv_init initialisiert, wobei der Tag wieder 1 und die Empfangsoperation nicht-blockierend ist. Der Einsatz der nicht-blockierenden Empfangsoperation stellt sicher, dass der Worker laufende Berechnungen bei Erhalt eines neuen Rechenauftrags abbricht und sofort mit der Berechnung der neuen Anfrage beginnt. Mehr hierzu im Paragraphen Empfangen der Rechenaufträge im Worker. Die Implementierung ist in Quelltext 25 zu sehen.

Senden der Rechenaufträge im Host Im Host sind neue Rechenaufträge immer dann an die Worker zu übertragen, wenn das Flag mpi_send_regions vom entsprechenden

```

525 // Init persistent asynchronous send. Each process gets his own
526   Request, Status and Buffer
527 MPI_Request region_requests[world_size];
528 MPI_Status region_status[world_size];
529 Region persistent_send_buffer[world_size];
530 for (int rank = 0 ; rank < world_size ; rank++) {
531   MPI_Send_init(&persistent_send_buffer[rank], sizeof(Region),
532                 MPI_BYTE, rank, 1, MPI_COMM_WORLD, &region_requests[rank]);
531 }
```

Quelltext 24: Initialisierung des Persistent Communication Requests im Host

```

56 // Init persistent asynchronous receive
57 Region newRegion;
58 MPI_Request request;
59 MPI_Recv_init(&newRegion, sizeof(Region), MPI_BYTE, host_rank, 1,
60               MPI_COMM_WORLD, &request);
```

Quelltext 25: Initialisierung des Persistent Communication Requests im Worker

WebSocket-Thread gesetzt wurde. Hierbei wird Busy-Waiting eingesetzt, da das Empfangen von fertig berechnenden Regionen auch nur mit Busy-Waiting funktioniert und sich das Senden und Empfangen in der selben Schleife befindet. Mehr hierzu in Abschnitten Busy-Waiting und Genereller Aufbau der MPI-Kommunikation im Host.

Sind neue Rechenaufträge verfügbar, wird jede einzelne Region einem verfügbaren Worker zugeordnet, wobei jeder Worker maximal eine Region bekommt. Hierzu wird die Region aus der gemeinsamen Datenstruktur websocket_request_to_mpi in den Sendebuffer des Workers kopiert. Anschließend wird das nicht-blockierende standard Senden mit MPI_Start gestartet.

Falls nicht genügend Rechenprozesse zur Verfügung stehen (es also mehr zu berechnende Regionen als Rechenprozesse gibt), wird nur ein Fehler ausgegeben, da dieser Fall in der aktuellen Version unmöglich ist. Die restlichen Regionen, denen noch kein Rechenprozess zugeteilt wurde, werden nicht berechnet.

Um sicherzustellen, dass alle Sendeoperationen abgeschlossen sind, wird MPI_Waitall eingesetzt, welches den Thread des Hosts so lange blockiert, bis die Daten aus allen Sendebuffern ausgelesen wurden. Es wird jedoch nicht gewartet, bis das entsprechende Empfangen in den Workern gestartet bzw. beendet wurde.

Der Code hierzu ist in Quelltext 26 zu sehen.

Empfangen der Rechenaufträge im Worker Da der Worker laufende Berechnungen abbrechen soll, falls er einen neuen Rechenauftrag bekommt, wird eine nicht-blockierende Empfangsoperation verwendet (dessen Initialisierung wurde hier behandelt). Direkt nach der Initialisierung wird die Empfangsoperation mittels MPI_Start gestartet, der Worker lauscht also nach neuen Rechenaufträgen und empfängt diese im Hintergrund während das Programm weiterläuft.

Direkt danach beginnt eine Endlosschleife (sie stellt den wichtigsten Teil des Workers dar), die zunächst MPI_Test auruft, um zu überprüfen, ob ein neuer Rechenauftrag

```

537     std::lock_guard<std::mutex> lock(
538         websocket_request_to_mpi_lock);
539     if (mpi_send_regions == true) {
540         unsigned int transmit_counter = 0;
541         for (int rank = 0 ; rank < world_size && transmit_counter
542             < websocket_request_to_mpi.size() ; rank++) {
543             if (usable_nodes[rank] == true) {
544                 std::cout << "Host: Start invoking core " << rank
545                 << std::endl;
546                 // Copy requested Region from joint datastructure
547                 // "websocket_request_to_mpi" to MPI Send buffer
548                 // "persistent_send_buffer"
549                 std::memcpy(&persistent_send_buffer[rank], &
550                             websocket_request_to_mpi[transmit_counter++],
551                             sizeof(Region));
552                 // Start the clock for MPI communication
553                 mpiCommunicationStart[rank] = std::chrono::
554                     high_resolution_clock::now();
555                 // Start send to one Worker using persistent
556                 // asynchronous send
557                 MPI_Start(&region_requests[rank]);
558             }
559         }
560         if (transmit_counter != websocket_request_to_mpi.size())
561         {
562             std::cerr << "Not enough Workers to compute all
563             subregions." << std::endl;
564         }
565         std::cout << "Host: Start invoking all cores done." <<
566             std::endl;
567         // Wait to complete all send operations
568         MPI_Waitall(world_size, region_requests, region_status);
569         std::cout << "Host: Waitall returned. All send operations
570             are complete." << std::endl;
571         mpi_send_regions = false;
572     }

```

Quelltext 26: Senden neuer Rechenaufträge im Host

erfolgreich empfangen wurde.

Ist das nicht der Fall, so wird der Worker für eine Millisekunde gestoppt um die Prozessorlast zu reduzieren. Anschließend wird die Schleife von neuem begonnen.

Konnte etwas empfangen werden, so wird die empfangene Region aus dem Empfangspuffer des Persistent Communication Requests (newRegion) in einen neuen Speicherplatz (region) kopiert. Nun wird wieder MPI_Start aufgerufen, um nach neuen Rechenaufträgen lauschen zu können. Jetzt wird auch klar, warum der Puffer kopiert werden musste. Der Empfangspuffer wird nämlich wiederverwendet. Anschließend wird die Berechnung der empfangenen Region gestartet, wobei nach jedem berechneten Pixel mittels MPI_Test überprüft wird, ob eine neue Region empfangen wurde. Ist das der Fall, so wird die Berechnung abgebrochen und die Endlosschleife von vorne begonnen. Falls nicht, wird mit der Berechnung des nächsten Pixels fortgefahrene.

Der entsprechende Code ist in Quelltext 27 zu finden.

```

59 // Listen for incoming messages
60 MPI_Start(&request);
61 // Start with actual work of this worker
62 while (true) {
63     // Test if receive operation is complete
64     MPI_Test(&request, &flag, &status);
65     if (flag != 0) {
66         // Set current region to newRegion, copy value explicitly
67         std::memcpy(&region, &newRegion, sizeof(Region));
68         // Listen for incoming messages
69         MPI_Start(&request);
70         // Loop over every pixel
71         for (...) {
72             // Compute pixel
73             f->calculateFractal(...)
74             // Test if receive operation is complete
75             MPI_Test(&request, &flag, &status);
76             if (flag != 0) {
77                 // Start while loop again
78             }
79         }
80     } else {
81         // Reduce processor usage on idle
82         std::this_thread::sleep_for(std::chrono::milliseconds(1));
83     }
84 }
```

Quelltext 27: Empfangen neuer Rechenaufträge im Worker

3.7.3 Übertragung der berechneten Daten von den Workern zum Host

Um dem vom Worker berechneten Teil der Mandelbrotmenge und zusätzliche Informationen wie beispielsweise die Rechendauer an den Host zu schicken, wird ebenfalls wieder MPI benutzt.

Struktur der zu übertragenden Daten Die Daten des Workers setzen sich aus zwei Teilen zusammen. Zum einen werden allgemeine Informationen in Form eines WorkerInfo-Structs an den Host geschickt. Dieses Struct beinhaltet den Rang des Workers, die Dauer der Berechnung und das zuvor empfangene Region-Struct, dass den Arbeitsauftrag enthält. Zum anderen müssen natürlich noch die berechneten Daten in Form eines unsigned short int Arrays gesendet werden.

Es ist dabei nicht praktikabel das Array mit den Daten in das WorkerInfo-Struct zu integrieren, da die Länge des Arrays von Region zu Region aufgrund des vorgenommenen Balancings unterschiedlich sein kann. Demnach wäre nur ein Pointer auf den wirklichen Speicherbereich (der außerhalb des Structs liegt) möglich. Wenn die Daten aber per MPI an einen anderen Prozess oder sogar an einen anderen Computer im Cluster gesendet

werden sollen, dann ist es nicht zielführend, wenn man nur den Pointer überträgt und nicht die Daten selbst. Auf den vom Pointer referenzierten Speicherbereich kann nämlich gar nicht zugegriffen werden.

Zur effizienten Lösung dieses Problems werden die beiden Datensätze hintereinander in den Speicher kopiert, wobei zuerst das WorkerInfo-Struct und dann die berechneten Daten kommen. Der Quellcode dazu ist in Quelltext 28 zu sehen.

Das Array mit den Daten ist eine eindimensionale Repräsentation der Fraktalwerte der Region. Die Umrechnung von x und y Koordinate innerhalb des Bereiches auf den Index i im Array erfolgt dabei nach folgender Regel, wobei region die berechnete Region ist $i = y * region.width + x$

```

154         // Pack "workerInfo" and the computed "data" in one
155         // coherent storage area "ret"
156         const unsigned int ret_len = sizeof(unsigned short int) *
157             data_len + sizeof(WorkerInfo);
158         uint8_t* ret = new uint8_t[ret_len];
159         std::memcpy(ret, &workerInfo, sizeof(WorkerInfo));
160         std::memcpy(ret + sizeof(WorkerInfo), data, data_len *
161             sizeof(unsigned short int));

```

Quelltext 28: Erstellen der Struktur aus WorkerInfo und den berechneten Daten

Senden der berechneten Daten im Worker Sobald die Berechnungen abgeschlossen sind, werden die Daten mit der blockierenden Standardsendeoperation MPI_Send mit Tag 2 übertragen. Es wurde die blockierende Variante gewählt, da die Sendeoperation der komplett berechneten Region abgeschlossen sein soll, bevor die Berechnung einer neuen Region startet. Zudem benötigt das Senden im Vergleich zum Berechnen sehr wenig Zeit, so dass die Komplexität, die eine nicht-blockierende Behandlung mitbringen würde in keinem Verhältnis zum Nutzen steht.

Der Code ist in Quelltext 29 zu finden.

```

161     // Send "ret" to the Host using one MPI_Send operation
162     MPI_Send(ret, ret_len, MPI_BYTE, host_rank, 2, MPI_COMM_WORLD);

```

Quelltext 29: Senden der berechneten Daten im Worker

Empfangen der berechneten Daten im Host Das Empfangen der Daten gestaltet sich etwas schwieriger als das Senden. Zunächst wird mit dem nicht-blockierenden MPI_Iprobe überprüft, ob neue Daten mit dem Tag 2 empfangen werden können. Damit Daten von jedem Worker empfangen werden können, wird als Source-Argument MPI_ANY_SOURCE angegeben. Liegen Daten zum empfangen an, so wird ein MPI_Status-Objekt von MPI_Iprobe ausgefüllt. Nun muss die Länge der zu empfangenden Daten ermittelt werden. Dazu wird MPI_Get_count mit dem gerade ausgefüllten Status-Objekt aufgerufen. Nachdem der Empfangspuffer in der entsprechenden Größe allokiert wurde,

wird die Nachricht mit einem blockierendem MPI_Recv empfangen. Es wurde der blockierende Empfangsmodus gewählt, da die Daten direkt im Anschluss weiterverarbeitet werden müssen und damit keine Arbeit zwischen dem Starten und Abschließen der Empfangsoperation erledigt werden kann. Nachdem MPI_Recv zurückgekehrt ist, werden die Daten wieder entsprechend der Vorgabe entpackt. Dann wird das WorkerInfo-Struct zusammen mit den berechneten Daten und der gestoppten Zeit der MPI-Kommunikation im Struct RegionData gespeichert und an einen WebSocket-Thread übergeben.

Die Implementierung ist in Quelltext 30 zu sehen.

```

562     // Listen for incoming complete computations from workers (MPI)
563     // Receive one message of dynamic length containing "workerInfo"
564     // and the computed "worker_data"
565     // TODO: asynchronous (maybe?)
566     MPI_Status status;
567     int probe_flag;
568     MPI_Iprobe(MPI_ANY_SOURCE, 2, MPI_COMM_WORLD, &probe_flag, &
569                status);
570     if (probe_flag == true) { // Rank: 2
571         probe_flag = 0;
572         int recv_len;
573         MPI_Get_count(&status, MPI_BYTE, &recv_len);
574         std::cout << "Host is receiving Data from Worker " << status.
575             MPI_SOURCE << " Total length: " << recv_len << " Bytes."
576             << std::endl;
577         uint8_t* recv = new uint8_t[recv_len];
578         int ierr = MPI_Recv(recv, recv_len, MPI_BYTE, status.
579                             MPI_SOURCE, 2, MPI_COMM_WORLD, MPI_STATUS_IGNORE); // Tag:
580                             2
581         if(ierr != MPI_SUCCESS){
582             std::cerr << "Error on receiving data from worker: " <<
583                     std::endl;
584             char err_buffer[MPI_MAX_ERROR_STRING];
585             int resultlen;
586             MPI_Error_string(ierr, err_buffer, &resultlen);
587             fprintf(stderr, err_buffer);
588             continue;
589         }
590
591         // Stop the clock for MPI communication
592         std::chrono::high_resolution_clock::time_point
593             mpiCommunicationEnd = std::chrono::high_resolution_clock::
594             now();

```

Quelltext 30: Empfangen der berechneten Daten im Worker

3.8 Berechnung der Mandelbrotmenge

Die Berechnung der einzelnen Punkte der Mandelbrotmenge ist in eine eigene Klasse ausgelagert. Wie bei der Lastbalancierung sind die Klassen nach dem Strategy-Pattern strukturiert, um eine spätere Erweiterung um andere Fraktale zu vereinfachen. Das

```

1 class Fractal {
2     public:
3     /**
4      * Calculates the fractal iteration value for a given complex (real,
5      * imaginary) pair
6      * @param cReal real coordinate
7      * @param cImaginary imaginary coordinate
8      * @param maxIteration maximum amount of iterations to perform
9      * @param vectorLength number of coordinates to be calculated at once
10     * @param dest memory position where result(number of iterations for
11       coordinates) should be stored
12     */
13     virtual void calculateFractal(precision_t* cReal, precision_t*
14         cImaginary, unsigned short int maxIteration, int vectorLength,
15         unsigned short int* dest) = 0;

```

Quelltext 31: Das gemeinsame Interface der Fraktale

Interface der Strategien ist hier in der Klasse `Fractal` (Quelltext 31) definiert.

Zusätzlich beinhaltet `Fractal` statische Methoden zur Berechnung der Deltas für Real- und Imaginärteil. Diese geben die Größe des Bereichs der komplexen Ebene an, der von einem Pixel überdeckt wird. So berechnet sich zum Beispiel das reelle Delta wie folgt:

$$\text{deltaReal} = \frac{\text{maxReal} - \text{minReal}}{\text{width}}$$

Die Berechnung des imaginären Deltas erfolgt analog. Die Deltas werden u.a. für die Berechnung des Fraktals in den Workern verwendet.

3.8.1 Berechnung ohne SIMD

Die Klasse `Mandelbrot` dient dazu jeweils einen Punkt der Mandelbrotmenge zu berechnen. Da hierbei keine Vektorisierung stattfindet ist es sinnvoll `vectorLength` auf 0 zu setzen. Es ist zu beachten, dass `cReal` und `cImaginary` als Zeiger auf diese Werte zu übergeben sind. Außerdem muss eine Speicherstelle für den Rückgabewert bereitgestellt und als `dest` übergeben werden. Diese Art und Weise der Übergabe macht ein gemeinsames Interface mit den vektorisierten Versionen möglich. Für die nicht parallele Berechnung wäre dies nicht nötig, da einzelne Werte auch direkt übergeben werden könnten.

Die Berechnung eines Punktes ist nun nicht weiter schwer, es muss lediglich Gleichung 1 als C++-Code umgesetzt werden. Bei $|z_n| > 2$ oder äquivalent $\text{Re}(z_n)^2 + \text{Im}(z_n)^2$ kann die Berechnung abgebrochen werden, da der Punkt sicher nicht in der Mandelbrotmenge liegt. Dies ist ebenfalls nötig wenn die maximale Anzahl an Iterationen erreicht wurde. Die benötigte Anzahl an Iterationen kann dann als Ergebnis zurückgegeben werden.

3.8.2 Berechnung mithilfe von SIMD

Um die Berechnungen intern noch zu beschleunigen, kann SIMD zur parallelen Bearbeitung mehrerer Punkte verwendet werden. Dazu ist es hilfreich, sich zunächst vor Augen zu führen, wie ein Vektor komplexer Koordinaten ohne SIMD verarbeitet würde. Dies ist in Quelltext 32 zu sehen. Die Berechnung der einzelnen Koordinaten bleibt gleich, nur die Abbruchbedingung wird auf alle bearbeiteten Koordinaten erweitert.

Es muss dabei solange weiter iteriert werden, bis für alle Komponenten die Berechnung abgebrochen werden darf. Hierbei ist es kein Problem, mit den abgebrochenen Punkten weiter zu rechnen, sofern die Iterationszahl nur hochgezählt wird solange das z_n der Koordinate Betagsmäßig kleiner gleich 2 ist. Dies gilt, da alle $|z_{n+i}| > 2$ sofern $|z_n| > 2$ [1].

Damit kann die Berechnung relativ simpel via Arm NEON Compiler Intrinsics²¹ implementiert werden (siehe dazu Quelltext 33). Diese Intrinsics ermöglichen eine Verwendung der nativen SIMD-Befehle, wobei der Compiler sich um die Verwendung der SIMD-Register kümmert. Dadurch wird lesbarer Code ermöglicht, der sich stärker am zu implementierenden Algorithmus orientiert.

Zu den hier benötigten mathematischen Operationen (z.B. der Addition) wird hierbei das Compiler Intrinsic nach folgendem Schema erzeugt: "vopcq_fpr" mit dem Operationscode *opc* (z.B. *add* für Addition). "v" ist das allgemeine Prefix für Vektoroperationen und "q" bedeutet, dass doppelt so viele Register verwendet werden wie ohne "q". Damit werden alle verfügbaren SIMD-Register des ARMv8-A Prozessors des ODroids und Raspberry Pi 3 B+ herangezogen. Das Postfix *fpr* bestimmt, dass die Register als Gleitkommazahlen der Präzision *pr* bit (in diesem Fall 32 oder 64) interpretiert werden sollen. Damit werden in jeder Operation 4 mal 32 bit Gleitkommazahlen oder 2 mal 64 bit Gleitkommazahlen verrechnet.

Bei der Implementierung wurden Optimierungen mithilfe der NEON-nativen multiply-add (*mla*) und multiply-subtract (*mls*) Befehle vorgenommen. Zudem kann der parallele Vergleich zweier Vektoren (*clt*) ausgenutzt werden, wobei als Ergebnis jedoch nicht 1 und 0 ausgegeben werden, sondern alle Bits der Ergebnisvektorkomponente auf 1 gesetzt werden sofern die Bedingung erfüllt ist und sonst auf 0. Um im weiteren Verlauf effizient die Vektorkomponenten aufzuaddieren (*addv*), sodass die Summe der Anzahl nicht abgebrochener Berechnungen entspricht, werden daher alle Komponenten des Ergebnisvektors des Vergleiches mit 1 verundet. Das Ergebnis des Vergleiches und der Verundung ist ein Vektor vorzeichenloser 32 oder 64 bit Ganzzahlen, weshalb das Postfix für diese Operationen *u32* oder *u64* lautet.

3.9 Erläuterung des Frontends

Um das Frontend zu implementieren, wurde sich für die Programmiersprache TypeScript²² (Erweiterung von JavaScript um Typisierung) entschieden. Da diese zu JavaScript kompiliert, werden die Vorteile von JavaScript, wie Ausführung im Webbrowser des

²¹Details im Abschnitt 'Compiler Intrinsics' unter <https://developer.arm.com/technologies/neon>

²²<https://www.typescriptlang.org/>

```

8 void MandelbrotVect::calculateFractal(precision_t* cReal, precision_t*
9   cImaginary, unsigned short int maxIteration, int vectorLength,
10  unsigned short int* dest) {
11    if (vectorLength <= 0){
12      throw std::invalid_argument("vectorLength may not be less than 1.
13      ");
14    }
15    std::fill_n(dest, vectorLength, 0);
16    precision_t* zReal = new precision_t[vectorLength];
17    precision_t* zImaginary = new precision_t[vectorLength];
18    precision_t* nextZReal = new precision_t[vectorLength];
19    precision_t* nextZImaginary = new precision_t[vectorLength];
20    // Factor that is added on iteration count
21    // is 0 or 1 and determines whether that point is still being
22    // computed
23    bool* factor = new bool[vectorLength];
24    std::fill_n(factor, vectorLength, 1);
25    // Integer storing number of Z components with absolute value
26    // below two => continue computation
27    unsigned int lessThanTwo = vectorLength; // as we begin with ZReal/
28    ZImag as 0
29    int i = 0;
30    while (i < maxIteration && lessThanTwo > 0){
31      lessThanTwo = 0;
32      for(int k = 0; k < vectorLength; k++){
33        // Compute next step in iteration
34        nextZReal[k] = (zReal[k] * zReal[k] - zImaginary[k] *
35          zImaginary[k]) + cReal[k];
36        nextZImaginary[k] = 2 * (zReal[k] * zImaginary[k]) +
37          cImaginary[k];
38        zReal[k] = nextZReal[k];
39        zImaginary[k] = nextZImaginary[k];
40        // Determine whether to stop
41        factor[k] = (zReal[k] * zReal[k] + zImaginary[k] * zImaginary
42          [k] < 4.0) ? 1 : 0;
43        // sum => if any number is still less than two, we need to
44        // continue
45        lessThanTwo += factor[k];
46        // increase number of iterations if this number wasnt aborted
47        yet
48        dest[k] += factor[k];
49      }
50    }
51    delete[] zReal;
52    delete[] zImaginary;
53    delete[] nextZReal;
54    delete[] nextZImaginary;
55    delete[] factor;
56  }

```

Quelltext 32: Bearbeitung eines Vektors komplexer Koordinaten in C++

```

29 // Load casted values from array to SIMD vector
30 float32x4_t cReal = vdupq_n_f32(0); // = vld1q_f32(cRealArray); if
   casting weren't necessary this would work
31 cReal = vsetq_lane_f32((float32_t) cRealArray[0], cReal, 0);
32 cReal = vsetq_lane_f32((float32_t) cRealArray[1], cReal, 1);
33 cReal = vsetq_lane_f32((float32_t) cRealArray[2], cReal, 2);
34 cReal = vsetq_lane_f32((float32_t) cRealArray[3], cReal, 3);
35 float32x4_t cImaginary = vdupq_n_f32(0);
36 cImaginary = vsetq_lane_f32((float32_t) cImaginaryArray[0],
   cImaginary, 0);
37 cImaginary = vsetq_lane_f32((float32_t) cImaginaryArray[1],
   cImaginary, 1);
38 cImaginary = vsetq_lane_f32((float32_t) cImaginaryArray[2],
   cImaginary, 2);
39 cImaginary = vsetq_lane_f32((float32_t) cImaginaryArray[3],
   cImaginary, 3);
40 // The z values
41 float32x4_t zReal = vdupq_n_f32(0);
42 float32x4_t zImaginary = vdupq_n_f32(0);
43 // Helper variables
44 float32x4_t two = vdupq_n_f32(2);
45 float32x4_t four = vdupq_n_f32(4);
46 uint32x4_t one = vdupq_n_u32(1);
47 // result iterations
48 uint32x4_t n = vdupq_n_u32(0);
49 // vector with 1 if absolute value of component is less than two
50 uint32x4_t absLesserThanTwo = vdupq_n_u32(1);
51 int i = 0;
52 // addv => sum all elements of the vector
53 while(i < maxIteration && vaddvq_u32(absLesserThanTwo) > 0){
54     // mls a b c -> a - b*c
55     float32x4_t nextZReal = vaddq_f32(vmlsq_f32(vmulq_f32(zReal,
      zReal), zImaginary, zImaginary), cReal);
56     // mla a b c -> a + b*c
57     float32x4_t nextZImaginary = vmlaq_f32(cImaginary, two, vmulq_f32(
      zReal, zImaginary));
58     zReal = nextZReal;
59     zImaginary = nextZImaginary;
60     // Square of the absolute value -> determine when to stop
61     float32x4_t absSquare = vmlaq_f32(vmulq_f32(zReal, zReal),
      zImaginary, zImaginary);
62     // If square of the absolute is less than 4, abs<2 holds -> 1
       else 0
63     absLesserThanTwo = vandq_u32(vcsltq_f32(absSquare, four), one);
64     // if any value is 1 in the vector (abs<2) then dont break
65     n = vaddq_u32(n, absLesserThanTwo);
66     i++;
67 }
68 // write n to dest
69 dest[0] = vgetq_lane_u32(n, 0);
70 dest[1] = vgetq_lane_u32(n, 1);
71 dest[2] = vgetq_lane_u32(n, 2);
72 dest[3] = vgetq_lane_u32(n, 3);

```

Quelltext 33: Parallelisierte Bearbeitung eines Vektors komplexer Koordinaten in 32 bit Gleitkommapräzision in C++ mit Arm NEON Compiler Intrinsics für SIMD

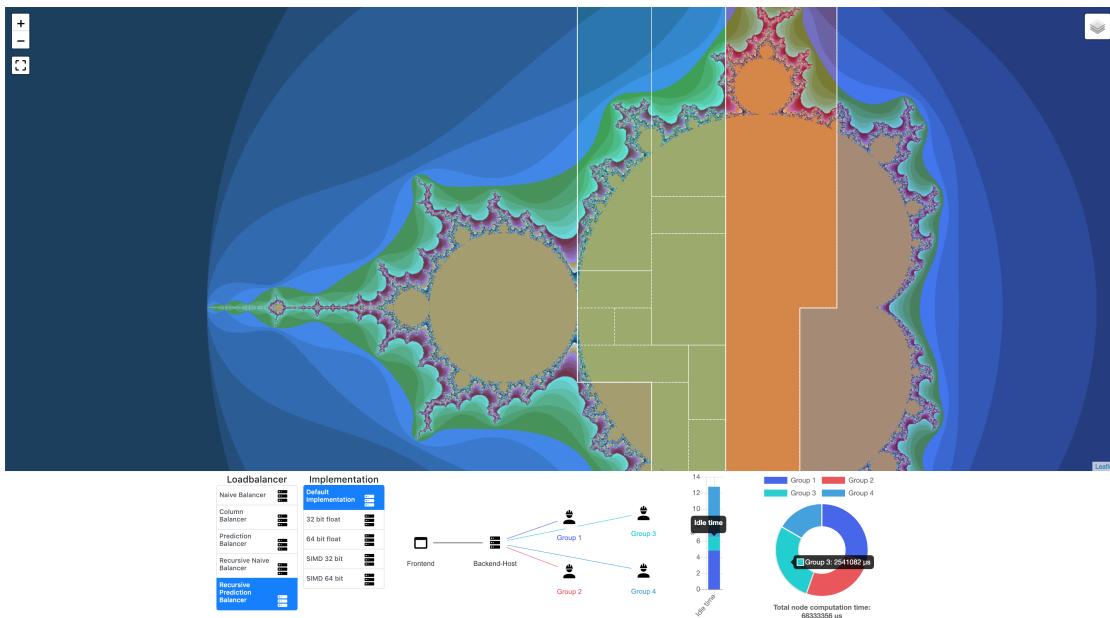


Abbildung 4: Benutzeroberfläche der Mandelbrot Anwendung

Benutzers und eine vielzahl verfügbarer Bibliotheken, mit den Vorteilen einer typisierten Programmiersprache vereint.

Für die graphische Benutzeroberfläche wurde ebenfalls TypeScript mit dem React Framework²³ verwendet, welches es ermöglicht, graphische Komponenten nativ in TypeScript zu erstellen und verändern. Es wurde für jede Komponente eine eigene TypeScript Klasse zu erstellt, welche dann den betreffenden das betreffende Verhalten und dessen Darstellung enthält.

Um das Fraktal darzustellen wird die Leaflet²⁴ Bibliothek verwendet. Diese, für Onlinekarten konzipierte, Bibliothek stellt den Bereich der komplexen Ebene, auf der die Mandelbrotmenge liegt dar. Dabei wird der momentan sichtbare Ausschnitt der Menge mit Hilfe der WebSockets Verbindung (siehe Unterunterabschnitt 3.9.1) an das Backend versendet und vom ausgewählten Lastbalancierer in Teilregionen unterteilt (siehe Unterabschnitt 3.6). Jeder der vom Backend berechneten Teilregionen wird, sobald diese empfangen wurden, im Frontend angezeigt und die Komponenten zu Visualisierung der Rechenzeit aktualisiert.

3.9.1 Kommunikation mit dem Backend

Zur Kommunikation mit dem Backend wird im Frontend ein Objekt der Klasse `WebSocketClient` erzeugt. Die zur Verbindung verwendeten Codestücke liegen dabei alle in dem Ordner `connection`, die genannte Klasse wird in `WSClient.ts` definiert.

²³<https://reactjs.org/>

²⁴<https://leafletjs.com/>

Die dort definierte Klasse `WebSocketClient` abstrahiert von dem JavaScript-nativen `WebSocket`interface²⁵. Bei der Initialisierung baut das erzeugte Objekt eine Verbindung zu der lokalen Adresse `ws://localhost:9002` auf²⁶. Dort sollte das Backend bereit sein, eine Websocketverbindung anzunehmen.

Zudem bietet die Klasse die Methode `sendRequest`, welche ein übergebenes `RegionRequest`-Objekt JSON-kodiert und versendet.

Wichtig für den Rest des Frontends sind die Methoden `registerRegion` und `registerRegionData`. An diese Methoden können Callbacks übergeben werden, die aufgerufen werden, wenn das Frontend über die Websocketverbindung respektive ein `Region`-Objekt oder ein `RegionData`-Objekt empfängt. Diese sind die Aufteilung einer angefragten Region (siehe Quelltext 17) oder die berechneten Iterationswerte einer Region (siehe Quelltext 18). Die übergebenen Callbacks erhalten als Parameter respektive die vorgruppierte Aufteilung als ein Array von Workergruppen (`RegionGroup`) oder das JSON-dekodierte `RegionData`-Objekt.

Zudem wird hierbei bereits eine Filterung der eingehenden Regionsdaten vorgenommen. Bei Empfang einer Regionsaufteilung, wird diese zwischengespeichert. Jedes empfangene Regionsdatenobjekt wird dann bei Empfang daraufhin überprüft, ob der darin dargestellte Ausschnitt einer Regionsaufteilung entspricht (dazu wird das `region`-Attribut verglichen) und das dargestellte Fraktal der zuletzt übergebenen Auswahl entspricht. Diese Filtrierung ist notwendig, da Worker Regionsdaten auch "verspätet" absenden können, falls bei dem zuvorgehenden Bereich nicht gewartet wurde bis die Berechnungen aller Worker entgegengenommen wurden.

Die Definitionen der zugehörigen Objekt-Interfaces finden sich in den Dateien `RegionGroup.ts` und `ExchangeTypes.ts`.

Als weitere Hilfsfunktion wird in `RegionRequest.ts` `request` bereitgestellt. Diese extrahiert aus der übergebenen Sicht auf die Mandelbrotmenge, die in der Leaflet-Karte gespeichert ist, die Parameter zum Anfragen einer Region. Dazu werden mithilfe des aktuellen Zooms der linke obere und rechte untere Punkt des Sichtbereiches in dem Leaflet-internen Koordinatensystem auf entsprechende Punkte in der komplexen Ebene projiziert. Da zum Erzeugen des passenden Objektes auch der gewünschte Lastbalancierer und der Fraktaltyp notwendig sind, werden diese als weitere Parameter übergeben. Die Funktion gibt direkt ein Objekt zurück, dass das Interface `RegionRequest` erfüllt.

3.9.2 Darstellung der Regionsdaten

Die für die Darstellung der Mandelbrotmenge verwendete Bibliothek (leaflet) hat die Einschränkung, dass nur Quadrate einer vordefinierten Größe (`Tiles`) angezeigt werden können. Ebenfalls verwendet diese ein eigenes Koordinatensystem, unter welchem jede

²⁵<https://developer.mozilla.org/en-US/docs/Web/API/WebSocket>

²⁶ Faktisch wird eine Verbindung geöffnet, geschlossen und erneut geöffnet. Dies ist durch ein ungelöstes Problem beim Verbindungsauflauf bedingt, das dafür sorgt, dass ein Verbindungsauflauf erst bei der zweiten erzeugten Websocketverbindung fehlerfrei gelingt.

angezeigte Tile eindeutig mit dem Tripel $(x, y, zoom)$ identifiziert wird. Somit ist eine Übersetzung zwischen den Daten des Backends und den von leaflet erwarteten nötig.

MatrixView.ts, RegionOfInterest.ts Die Klasse `MatrixView.ts` implementiert die Umsetzung einer vom Backend versendeten Region zu den von leaflet erwarteten Tiles. Dafür registrieren sich alle sichtbaren Tiles durch die Methode `registerTile(point, draw)` mit dem Callback `draw`, welcher ausgeführt wird, sobald die anzuzeigenden Daten für die entsprechende Tile verfügbar sind. Diese Iterationswerte des Backends werden dabei der `draw` Funktion als Parameter in Form eines `RegionOfInterest` Objekts übergeben.

Ein `RegionOfInterest` Objekt implementiert wiederum die Übersetzung von lokalen (x, y) Pixel-Werten einer Tile zu Indizes in die vom Backend gesendeten Regionsdaten (siehe Quelltext 18). Dabei gibt die `get(x, y)` Methode, für einen Tile (x, y) Pixel-Wert die benötigte Iterationsanzahl zurück (siehe Quelltext 34).

```

39  * @param {Number} y pixel y coordinate of the tile
40  */
41  public get(x: number, y: number): number {
42    if (x > this.ROIWidth || y > this.ROIHeight) {
43      return -1;
44    }
45    let realX = this.topLeft.x + x;
46    let realY = this.topLeft.y + y;

```

Quelltext 34: Umsetzung von Pixel-Werten der Tiles zu Indizes in Regionsdaten

TileDisplay.tsx Die Klasse `TileDisplay.tsx` verwendet die leaflet Bibliothek direkt, um die Regionsdaten darzustellen. Dabei wird dieser die WebSocket Verbindung in Form eines `WebSocketClient`, sowie der vom Nutzer gewählte Balancer, die Implementierung und Gruppierung durch `Observable` Klassen (siehe Abschnitt 3.9.5) übergeben. Ebenfalls wird der anzuzeigende Ausschnitt der Mandelbrotmenge übergeben.

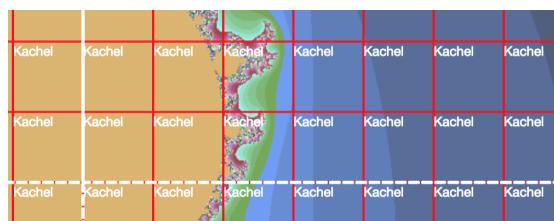


Abbildung 5: Relation von Backend Regionen zu leaflet Tiles

Da das Backend die berechneten Teilbereiche der Mandelbrotmenge als Regionen zurück gibt, dessen Höhe und Breite Vielfache der leaflet Tile-Größe sind, wird eine Region dem Benutzer durch mehrere Tiles dargestellt. Dieses Verhältnis wird in Abbildung 5 dargestellt. Dabei ist beispielhaft eine Region des Backends weiß eingezeichnet, alle

leaflet Tiles sind rot umrandet angegeben. Eine detailliertere Version dieser Anzeige kann durch die Auswahl des DebugLayers jederzeit im Frontend eingeblendet werden.

Dargestellt werden die Tiles in einer eigenen Ebene der leaflet Karte, dem `MandelbrotLayer`. Dieser erstellt für den sichtbaren Bereich²⁷ alle benötigten Tiles. Für jede der Tiles wird ein HTML5 `canvas`²⁸ Objekt erstellt, welches es ermöglicht, für jeden Pixel einen (r, g, b) Farbwert zu definierten und anzuzeigen. Wobei die Farbwerte aus den berechneten Iterationswerten des Backends mit einem Shader (siehe Abschnitt 3.9.2) ermittelt werden. Die Iterationswerte können wiederum mit einem `MatrixView` Objekt aus den Regionsdaten des Backends gelesen werden.

Weiterhin wird in `TileDisplay` der `WorkerLayer` (siehe Abschnitt 3.9.2), welcher die Regionsaufteilung des Backends visualisiert, hinzugefügt und callbacks auf die Observables definiert, welche die momentan sichtbare Region erneut vom Backend anfordern, falls sich einer der ausgewählten Lastbalancierer, oder die gewählte Implementierung ändert.

Shader.ts Berechnet für einen Iterationswert der Mandelbrotmenge ein Tripel (r, g, b) von Farbwerten. Implementiert ist eine simple Funktion, welche den Iterationswert für jeden Farbkanal mit einer Konstante multipliziert und auf den zulässigen ganzzahligen Wertebereich $[0, 255]$ abbildet (siehe Quelltext 35).

```

2  public static default(n: number, maxIteration: number): number[] {
3    const r = (n * 10) % 256;
4    const g = (n * 20) % 256;
5    const b = (n * 40) % 256;
6    return [r, g, b];
7 }
```

Quelltext 35: Berechnung der (r, g, b) Farbwerte

Project.ts Da die leaflet Bibliothek Tiles verwendet, um die Regionen des Backends anzuzeigen, liegen diese Tiles in einem neuen Koordinatensystem, welches jeder Tile auf einer Zoomstufe ein Triple $(tileX, tileY, zoom)$ zuordnet. Weiterhin besitzt leaflet ein internes Koordinatensystem (CRS²⁹), welches jeden Punkt auf der Karte durch das Paar $(latitude, longitude)$ identifiziert. `Projekt.ts` enthält Funktionen, um zwischen diesen 3 Koordinatensystemen (Tile-Koordinaten, leaflet-Koordinaten und Koordinaten der komplexen Ebene) zu konvertieren.

Regionsgruppierung (`RegionGroup.ts`)

²⁷Da die Fenstergröße des sichtbaren Bereichs kein Vielfaches der Tilegröße sein muss, können Tiles erzeugt werden, welche teilweise außerhalb des sichtbaren Bereichs liegen

²⁸https://developer.mozilla.org/kab/docs/Web/API/Canvas_API

²⁹https://en.wikipedia.org/wiki/Spatial_reference_system

WorkerLayer.ts Diese Klasse visualisiert die Regionsaufteilung des Lastbalancierers als Overlay, welche über den Iterationswerten dem Benutzer angezeigt wird. Dafür wird eine in leaflet bestehende GeoJSON API verwendet, mit welcher es möglich ist, beliebige Polygone auf den bestehenden Kartendaten anzuzeigen. Die Eckpunkte für diese Polygone für jede RegionGroup mit Hilfe der Funktionen aus Project von Koordinaten der komplexen Ebene, welche im Backend verwendet werden, zu leaflet Koordinaten umgerechnet.

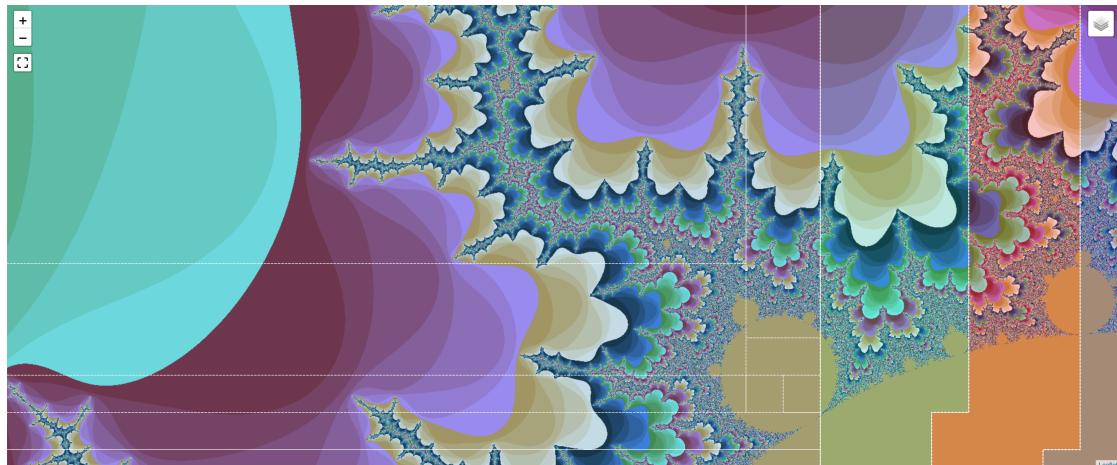


Abbildung 6: Gruppierung einer Aufteilung des Recursive PredictionBalancers mit 37 Workern

Da es wie in Abschnitt 3.9.2 beschrieben zu einer Gruppierung kommt, falls die Anzahl der Worker im Backend zu groß ist, werden ebenfalls alle Untergruppen einer Gruppe angezeigt (siehe Abbildung 6), falls der Benutzer mit der Maus über eine der dargestellten Gruppierungen geht.

3.9.3 Visualisierung der Programmstruktur

Die Struktur der Parallelisierung wird in einem Netzwerkgraphen unter dem Fraktal dargestellt. Mithilfe der Bibliothek visjs³⁰ wird hierzu ein Graph mit 3 Ebenen erzeugt: Auf der linken Seite befindet sich ein Knoten in Form eines Programmfensters, der das Browserfrontend darstellt. In der Mitte wird ein Knoten für den Backend-Host mit Serverrack als Symbol dargestellt, der mit dem Frontendknoten verbunden ist. Auf der rechten Seite befindet sich schließlich zwischen 2 und 4 Knoten, die jeweils eine Gruppe an Arbeitern darstellen. Das Symbol hierfür ist ein Oberkörper mit Arbeitshelm. Sie sind wiederum direkt mit dem Host verbunden.

Der Code für diese Darstellung findet sich in components/NetworkView.tsx. Dort wird ein Baumgraph von links nach rechts mit manueller Ebenenverteilung als Grundstruktur für die Darstellung des Graphen definiert. Daher wird das Frontend auf der

³⁰<http://visjs.org/>

höchsten Ebene und der Backend-Host auf der Ebene darunter spezifiziert. Die Arbeiter werden auf Basis der erhaltenen Regionsaufteilung erzeugt und jeweils zu zweit nacheinander auf Ebenen verteilt. Diese Aufteilung wird nach Erhalt jeder Regionsaufteilung vorgenommen und der Graph neu aufgebaut, sowie die Größe der Leinwand an die Anzahl an Knoten angepasst.

3.9.4 Visualisierung der Rechenzeiten

Die zeitbezüglichen Komponenten der Visualisierung werden mithilfe der Charts der Bibliothek chart.js³¹ dargestellt.

Idle Time Für die kritische Information der verschwendeten Zeit wird ein Balkengraph verwendet. Dieser besitzt einen Balken, der die Differenz zwischen der Rechenzeit aller Knoten und dem am längsten rechnenden Knoten aufsummiert und nach Gruppe sortiert darstellt. Die Darstellung wird bei Empfang einer Regionsaufteilung (mithilfe registerRegion in dem Websocketclient) initialisiert indem die Anzahl an Knoten und die Gruppen gespeichert, die Rechenzeit der Knoten auf 0 gesetzt und alle Knoten als aktiv markiert werden. Da die tatsächliche Rechenzeit erst am Ende der Berechnung mit den Regionsdaten selbst verfügbar ist, wird mithilfe eines Intervalls die Rechenzeit live abgeschätzt, indem sie simpel alle 50 Millisekunden um 50 Millisekunden hochgezählt wird, falls die Regionsdaten des Knotens noch nicht empfangen wurden. Da die Charts nicht zur Animation von Übergängen fähig sind, wird das Objekt mit jedem Update neu gerendert. Bei Empfang von Regionsdaten (hierzu wird die erwähnte Methode registerRegionData verwendet) wird die tatsächlich gemessene Rechenzeit eingetragen und der Rechenknoten als inaktiv gekennzeichnet. Der Intervall wird gestoppt, sobald alle Arbeiterknoten die Berechnung abgeschlossen haben. Einiges an Code ist dabei nur dafür zuständig, beim Schweben über einem Teil des Balkens die Wartezeit einer einzelnen Gruppe in einem Tooltip darzustellen.

ComputationTime Zur Darstellung des relativen Verhältnisses der Rechenzeiten wird in einem Kuchengraph die absolute Rechenzeit der Gruppen dargestellt.

3.9.5 MISC

Observable.ts

³¹<http://www.chartjs.org/>

4 Ergebnisse / Evaluation

- Skalierbarkeitsgraph
- Wie gut ist SIMD / OpenMP / MPI / Mischformen?
- Frontend Overhead messen

Notiz, entdeckt durch das In-Betracht-Ziehen der Leerregionen:

Probleme bei der Verwendung des Rekursiven Lastbalanierers: Da es stets im Diskreten eine Minimalgröße für die aufgeteilten Regionen gibt, kann es sein, dass eine Region für die eine hohe Last vorhergesagt wird viele Worker reserviert - diese jedoch nicht vollständig ausreizen kann, da die Maximalaufteilung schon erreicht wurde. Durch die dadurch entstehenden Leerregionen von nicht verwendbaren Workern kann eine suboptimale Aufteilung entstehen, schlechter noch als die des naiven rekursiven Balancierers.

Dies kann abgeschwächt werden, indem eine Region stets nur soviel Workerressourcen erhält, wie sie maximal auslasten könnte (Fläche/Fläche minimaler Aufteilung)

5 Zusammenfassung

- Zusammenfassung
- Ausblick

Abbildungsverzeichnis

| | | |
|---|--|----|
| 1 | Die Mandelbrotmenge, visualisiert in einem Ausschnitt des komplexen Zahlenraumes. | 4 |
| 2 | Architekturübersicht | 7 |
| 3 | Konzept der Koordinaten in den Regionsobjekten. Alle Koordinaten beziehen sich auf die Darstellungsebene und sind daher in Pixeln. | 17 |
| 4 | Benutzeroberfläche der Mandelbrot Anwendung | 41 |
| 5 | Relation von Backend Regionen zu leaflet Tiles | 43 |
| 6 | Gruppierung einer Aufteilung des Recursive PredictionBalancers mit 37 Workern | 45 |

Tabellenverzeichnis

Literatur

- [1] mrf (<https://math.stackexchange.com/users/19440/mrf>). Why is the bailout value of the mandelbrot set 2? Mathematics Stack Exchange. URL:<https://math.stackexchange.com/q/424331> (version: 2013-06-24).
 - [2] zaphoyd (<https://www.zaphoyd.com/>). Websocket++ user manual. Zaphoyd.com. URL:<https://www.zaphoyd.com/websocketpp/manual/reference/thread-safety> (version: 2013-03-02).
-